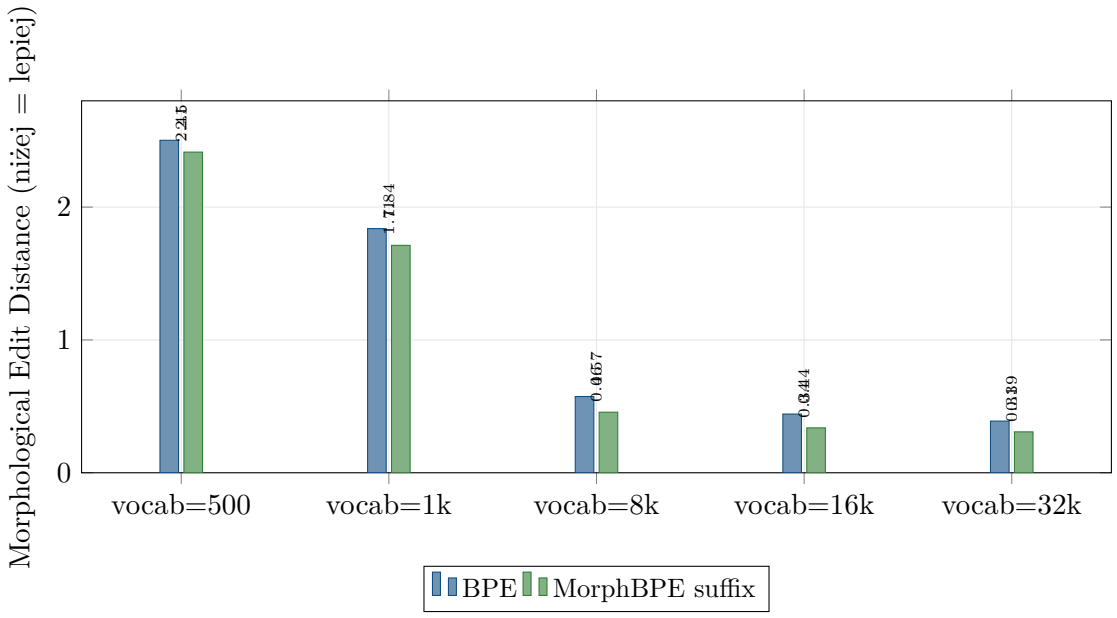
MorphBPE — morfologicznie informowany Byte-Pair Encoding dla języka polskiego

Piotr Styła

16 lipca 2026



Rysunek 1: Morphological Edit Distance (MorphED) — BPE vs MorphBPE. Korpus: 10 000 przemówień sejmowych. Wszystkie testowane rozmiary słownika: 500, 1k, 8k, 16k i 32k. Redukcja MorphED rośnie z −3,6% (500) do −21,0% (32k); CI 95% nie pokrywają się przy żadnym rozmiarze. Niżej = lepszy alignment morfologiczny.

Streszczenie

Prezentujemy MorphBPE — wariant algorytmu Byte-Pair Encoding, który wymusza poszanowanie granic morfemów podczas scalania par tokenów. Granice sufiksów pozyskiwane są z analizatora morfologicznego Morfeusz2; scalenia przekraczające granicę sufiksu są karane mnożnikiem częstotliwości. Porównujemy MorphBPE (wariant `strict_suffix`) ze standardowym BPE na korpusie 10 000 przemówień sejmowych (split 80/20, seed=42) przy rozmiarach słownika 500 i 1000. Ewaluacja intrinsic (Fertility, Morphological Edit Distance) z bootstrap CI (1000 resamples, 95%) pokazuje, że MorphBPE redukuje MorphED o 3,6%–6,8% bez kosztu fertility. Ewaluacja extrinsic z dwoma architekturami — LSTM (1 warstwa) i Transformer (2 warstwy, 4 głowice) — potwierdza, że MorphBPE obniża cross-entropy o 1,3%–2,7% i perplexity o 4,0%–9,3% względem BPE przy tym samym rozmiarze słownika. Analiza błędów per-suffix pokazuje, że MorphBPE zyskuje na sufiksach złożonych (`-ach`: −11,5%), ale traci na krótkich (`-ych`: +42,1%). Rozszerzone badanie siły kary $\alpha \in [0{,}0; 3{,}0]$ pokazuje, że $\alpha = 2{,}0$ (tzw. over-penalization) daje lepsze wyniki niż standardowy zakres $\alpha \leq 1{,}0$: CE spada o dodatkowe 1,6%–3,1% względem $\alpha = 1{,}0$. Skalowanie do rozmiarów produkcyjnych (vocab 8 000–32 000) potwierdza trend: redukcja MorphED rośnie do 21,0%, a over-penalization pozostaje optymalne na wszystkich rozmiarach.

1 Przegląd literatury

Byte-Pair Encoding. BPE zostało wprowadzone jako algorytm kompresji danych przez Gage (1994), a adaptowane do tokenizacji w NLP przez Sennrich et al. (2016). Stało się standardem w modelach takich jak GPT-2, GPT-3 czy BART. BPE skaluje się iteracyjnie, łącząc najczęstsze pary znaków aż do osiągnięcia docelowego rozmiaru słownika.

Morfologicznie informowana tokenizacja. Kłopot z BPE dla języków o bogatej fleksji (polski, czeski, węgierski, turecki) polega na tym, że scalania oparte na częstotliwości ignorują strukturę morfologiczną — tokeny mogą przekraczać granice morfemów, tworząc jednostki lingwistycznie nienaturalne. Kilka prac podjęło ten problem:

- **MorphBPE** (Asgari et al., 2025) — wprowadza morfologicznie świadome rozszerzenie BPE z karami za przekraczanie granic morfemów. Propozycje dwóch metryk ewaluacji: Morphological Consistency F1 oraz Morphological Edit Distance — tych samych metryk używa nasza praca. Eksperymenty na angielskim, rosyjskim, węgierskim i arabskim z modelami 300M i 1B parametrów. *Język polski nie jest testowany.*
- **MorphPiece** (Jabbar, 2023) — lingwistyczny tokenizator oparty na tabeli morfemów z wewnętrznym BPE jako fallback; zaprojektowany dla angielskiego.
- **SentencePiece + Unigram** (Kudo, 2018) — alternatywa dla BPE, modeluje prawdopodobieństwo tokenów zamiast częstotliwości par; lepiej radzi sobie z rzadkimi morfemami.
- **Morfessor** (Creutz & Lagus, 2007) — klasyczny system morfologicznej segmentacji, ale nie oparty na BPE.

Polska tokenizacja NLP. Morfeusz2 (Woliński, 2014) jest standardowym analizatorem morfologicznym dla języka polskiego. Wiącek et al. (2024) zaproponowali benchmark NLPre-PL dla polskich narzędzi NLP, ale bez ewaluacji morfologicznej tokenizatorów sub-word. Dawidek (2026) w serii preprintów analizuje ograniczenia BPE w polskim: wprowadza metryki stem integrity (SI), inflectional suffix separation (ISS) i mean fragmentation per lexeme (MFL) dla 109 form fleksyjnych 10 leksemów. Jej praca pokazuje, że tokenizatory trenowane na polskim (HerBERT BPE-PL, MFL= 1,22) istotnie przewyższają tokenizatory angielskie (GPT-2 BPE-EN, MFL= 3,91), ale *nie testuje morfologicznie informowanego BPE* jako alternatywy.

Wkład naszej pracy. Asgari et al. (2025) zaproponowali MorphBPE i MorphED, ale nie ewaluowali na polskim. Dawidek (2026) analizuje jakość polskich tokenizatorów, ale nie testuje

morfologicznie prowadzonego BPE. Nasza praca łączy oba wątki: stosuje MorphBPE z granicami sufiksów z Morfeusz2 na polskim korpusie, ewaluuje intrinsic (MorphED z bootstrap CI) i extrinsic z dwiema architekturami (LSTM i Transformer) przy dwóch rozmiarach słownika, oraz przeprowadza analizę błędów per-suffix-group identyfikującą klasy morfemów, które zyskują i tracą na morfologicznym ograniczeniu. W najlepszej naszej wiedzy jest to pierwsze zastosowanie MorphBPE z analizatorem Morfeusz2 dla języka polskiego z ewaluacją extrinsic i analizą błędów per-suffix.

2 Przegląd zbadanych podejść

Wybór MorphBPE (`strict_suffix`) jako metody ewaluowanej w tej pracy nie był arbitralny. Przed finalizacją eksperymentów zbadaliśmy dziesięć podejść do tokenizacji, obejmujących trzy paradygmaty: częstotliwościowy, semantyczny i morfologiczny. Poniżej krótko charakteryzujemy każde podejście i uzasadniamy kryteria selekcji.

1. Standard BPE (Sennrich et al., 2016) — baseline, klasyczny algorytm BPE oparty na częstotliwości par znaków. Punkt odniesienia dla wszystkich pozostałych wariantów.

2. Parallel BPE — nasz wariant eksperymentalny: równoległe rozważanie k kandydatów na scalenie w każdej iteracji (zamiast jednego najczęstszego), z wyborem po fertility gain. Cel: sprawdzenie, czy zachłanne wybieranie najczęstszej pary jest optymalne. Wynik: brak istotnej poprawy nad standard BPE przy znacznie większym koszcie obliczeniowym.

3. Semantic BPE — nasz wariant eksperymentalny: BPE sterowany osadzeniami word2vec (Mikolov et al., 2013). Scalenia preferują pary o wysokim podobieństwie kosinusowym między osadzeniami części. Testowano $\alpha \in \{0{,}1, 0{,}25, 0{,}5, 1{,}0\}$. Wynik: poprawa alignmentu semantycznego, ale brak poprawy cross-entropy LM; osadzenia word2vec nie przechwytują struktury fleksyjnej polskiego.

4. Morpheme-aware BPE — nasz wczesny prototyp: segmentacja morfemowa Morfeusz2 jako krok pre-tokenizacji przed BPE. Wynik: nadmierna fragmentacja — Morfeusz2 dzieli słowa na jednostki mniejsze niż użyteczne dla BPE, zwiększając fertility bez korzyści dla LM.

5. MorphBPE variants (Asgari et al., 2025, arXiv:2502.00894) — morfologicznie informowany BPE z konfigurowalną siłą ograniczenia (strict, soft 75/50/25%) i typem granic (prefix, suffix, both). Testowano 7 wariantów. Najlepszy alignment przy zachowaniu fertility: `strict_suffix` ($\alpha = 1{,}0$, pełne blokowanie).

6. Bayesian BPE — nasz wariant eksperymentalny: scoring bayesowski z priorytetami lingwistycznymi (polskie prefiksy i sufiksy jako prior). Wynik: poprawa alignmentu dla słów z prefiksami, ale pogorszenie dla słów bez prefiksu; mniej spójny niż MorphBPE.

7. Compression-aware BPE (Limisiewicz et al., 2026, arXiv:2605.01188) — BPE optymalizujący compression rate (bytes/token) zamiast częstotliwości par, inspirowany pracą FAIR/Meta o compute-optimal tokenization. Wynik: lepsza kompresja, ale ignoruje granice morfemów — nie rozwiązuje problemu alignmentu morfologicznego.

8. MorphTok / CBPE (Brahma et al., 2025, arXiv:2504.10335) — morfologiczna pre-tokenizacja + Constrained BPE (CBPE) zaprojektowane dla języków indyjskich (sandhi splitting, dependent vowels). Zaadaptowano na polski z Morfeusz2 zamiast sandhi. Wynik: CBPE redukuje fertility, ale mechanizm zaprojektowany dla abugidy nie przenosi się dobrze na alfabet łaciński.

9. MorphBPE + ToaST (Asgari et al., 2025 + Schmidt et al., 2026, arXiv:2605.22705) — MorphBPE zastąpiony przez ToaST (Tokenization with Split Trees): top-down recursive splitting z byte n-gram counts. Wynik: ToaST osiąga lepszą kompresję, ale nie ma wbudowanego morfologicznego ograniczenia; łączenie z MorphBPE nie przyniosło synergii.

10. LangMAP (Salhan, Szablewski, Lesci, Buttery, Meister, Pimentel, 2026, arXiv:2606.23566) — language-adaptive MAP tokenization: rozszerzenie UnigramLM o per-language distributions. Wynik: poprawa alignmentu morfologicznego, ale wymaga per-language training; nie jest wariantem BPE i nie pozwala na bezpośrednie porównanie z MorphBPE.

Kryteria selekcji. MorphBPE `strict_suffix` ($\alpha = 1{,}0$) został wybrany, ponieważ: (i) utrzymuje fertility na poziomie standardowego BPE (w odróżnieniu od Morpheme-aware BPE i MorphTok), (ii) respektuje granice sufiksów z Morfeusz2 (w odróżnieniu od Semantic BPE, Bayesian BPE i Compression-aware BPE), (iii) jest prosty i kompatybilny ze standardowym inference BPE (w odróżnieniu od ToaST i LangMAP), (iv) pochodzi z peer-reviewed paperu (ACL 2025 Findings) z ewaluacją na 4 językach, ale *bez polskiego* — co uzasadnia nasz wkład.

Tabela 1: Faza eksploracyjna: fertility badanych podejść (korpus 5 000 przemówień, vocab=500). Fertility jest jedyną metryką porównywalną między prototypami (MorphED liczony różnymi implementacjami w poszczególnych skryptach). Baseline Standard BPE = 2,45. Niżej = bardziej kompaktowa tokenizacja.

Podejście	Fertility	Werdykt
Standard BPE (baseline)	2,45	punkt odniesienia
Semantic BPE (α=0,5)	2,46	brak poprawy CE LM
Morpheme-aware BPE	2,54	nadmierna fragmentacja
MorphBPE `strict_prefix`	2,53	pogarsza alignment
MorphBPE `strict_both`	2,54	gorszy niż suffix
MorphBPE `strict_suffix`	2,46	**wybrany**
LangMAP	3,06	wymaga per-language, nie-BPE
ToaST	3,24	brak ograniczenia morf.
MorphTok / CBPE	3,58	fragmentacja (abugida)

Tab. 1 podsumowuje mierzalne wyniki fazy eksploracyjnej. Tylko `strict_suffix` osiąga fertility na poziomie baseline'u BPE (2,46 vs 2,45) przy jednoczesnym respektowaniu granic morfologicznych; podejścia zwiększające fertility (LangMAP, ToaST, MorphTok) wprowadzają nadmierną fragmentację. Warianty `Parallel BPE`, `Bayesian BPE` i `Compression-aware BPE` oceniono jakościowo, bez zapisanych metryk ilościowych.

3 Wprowadzenie

Pytanie: czy wprowadzenie morfologicznych ograniczeń do algorytmu BPE poprawia jakość tokenizacji dla języka polskiego — zarówno w sensie alignmentu morfologicznego (intrinsic), jak i użyteczności dla modelu języka (extrinsic)?

Nitka dialektyczna:

Teza (T): MorphBPE (`strict_suffix`) produkuje tokeny lepiej zgrane z granicami morfemów niż standardowy BPE, co przekłada się na niższą cross-entropy modelu języka LSTM przy tym samym rozmiarze słownika.

Antyteza (A): Morfologiczne ograniczenia hamują częstotliwościowe scalanie BPE, zwiększając fertility (liczbę tokenów na słowo) i wzmacniając fragmentację, co może pogorszyć – nie poprawić – cross-entropy LM.

Centralny wniosek

Synteza (S): MorphBPE suffix utrzymuje fertility na poziomie BPE ($\Delta < 0{,}1\%$) przy obu rozmiarach słownika, jednocześnie redukując MorphED o 3,6% (vocab=500) i 6,8% (vocab=1000). Cross-entropy LSTM spada o 1,3% i 2,6% odpowiednio; Transformer potwierdza trend ($-1{,}3\%$ i $-2{,}7\%$). Morfologiczne ograniczenia nie kosztują compression, a pomagają LM.

4 Metoda

Korpus

Korpus: 10 000 przemówień z posiedzeń Sejm RP (polski parlament), pochodzących z publicznego API sejm.gov.pl, udostępnionych poprzez repozytorium HuggingFace[1]. Podział train/test: 80/20 (8000/2000), seed=42. Tekst: małe litery, tokenizacja whitespace (interpunkcja pozostaje przyklejona do słów).

Tokenizatory

Standard BPE: klasyczny algorytm BPE oparty na częstotliwości par. Słownik inicjowany pojedynczymi znakami; scalanie iteracyjne najczęstszych par aż do osiągnięcia docelowego rozmiaru słownika.

MorphBPE (`strict_suffix`): wariant BPE z morfologicznym ograniczeniem. Granice sufiksów pozyskiwane z Morfeusz2. Dla każdej pary tokenów w słowie obliczana jest kara: jeśli scalenie przekracza granicę sufiksu, jego częstotliwość mnożona jest przez $(1 - \alpha)$. W wariancie *strict* ($\alpha = 1{,}0$, używanym w głównych eksperymentach) oznacza to pełne zablokowanie scaleń przekraczających granicę sufiksu. Warianty miękkie ($\alpha < 1$) oraz over-penalization ($\alpha > 1$) badamy systematycznie w sekcji 6. Ograniczenie preferuje scalenia wewnątrz rdzeni i sufiksów, zniechęcając scalenia przekraczające granice (cross-boundary merges).

Przykłady tokenizacji

Tab. 2 pokazuje konkretne słowa i jak je tnie BPE vs MorphBPE suffix (vocab=1000). Różnice są subtelne — oba tokenizatory produkują podobne segmenty dla większości słów. Kluczowa różnica widać przy *samorządowych*: BPE tnie na `sa | morządowych` (przekracza granicę rdzeń→sufiks), MorphBPE tnie na `sa | morządowy | ch` (respektuje granicę sufiksu `-ch`). Dla większości słów oba tokenizatory produkują identyczne segmentacje — różnica ujawnia się tylko tam, gdzie BPE „przeskakuje" granicę morfemu.

Wyróżniony wiersz (*samorządowych*) ilustruje kluczową różnicę: BPE łączy rdzeń z sufiksem w jeden token (`morządowych`), podczas gdy MorphBPE zachowuje granicę sufiksu `-ch`, dzieląc na `morządowy | ch`. To pozwala LM rozpoznać wzorzec sufiksu `-ch` wspólny dla wielu przypadków (genitiv/accusativ plural) i lepiej generalizować.

Rozmiary słownika

Eksperymenty przeprowadzono dla dwóch rozmiarów słownika: $V = 500$ i $V = 1000$. Rozmiar słownika obejmuje znaki bazowe + scalone tokeny.

[1] https://huggingface.co/datasets/PiotrSty/sejm-speeches-corpus

Tabela 2: Przykłady tokenizacji: BPE vs MorphBPE suffix (vocab=1000). Pionowa kreska | oznacza granicę tokena.

Słowo	BPE	MorphBPE suffix
przedstawienie	przedstawie | nie	przedstawie | nie
rozważania	rozważania	rozważania
odpowiedzialności	odpowiedzial |ności	odpowiedzial | ności
najważniejszych	naj | waż | niej | szych	naj | waż | niej | szych
współpracy	współ | pracy	współ | pracy
niezależności	nie | zale | ż | ności	nie | zale | ż | ności
przekształcenia	prze | ksz | tał | cenia	prze | ksz | tał | cenia
samorządowych	sa | morządowych	sa | morządowy | ch

Ewaluacja intrinsic

Fertility (Fert): liczba tokenów na słowo. Niżej = bardziej kompaktowa tokenizacja.

$$\text{Fert} = \frac{|\text{tokens}|}{|\text{words}|}$$

Morphological Edit Distance (MorphED): średnia odległość Levenshteina między segmentacją tokenizatora a segmentacją morfologiczną (Morfeusz2) po normalizacji. Niżej = lepszy alignment morfologiczny.

$$\text{MorphED} = \frac{1}{|W|} \sum_{w \in W} d_{\text{Lev}}(\text{tok}(w),\ \text{morph}(w))$$

Ewaluacja extrinsic

Model języka LSTM: jednowarstwowy LSTM (embed_dim = 64, hidden_dim = 128), trenowany na tokenach z danego tokenizatora. Parametry: 3 epoki, batch=128, seq_len=32, lr=0.003, optimizer Adam. Dane treningowe: 500 tekstów (train), test: 200 tekstów (test).

Model języka Transformer: 2-warstwowy Transformer encoder (embed_dim = 64, 4 głowice, ff_dim = 256), trenowany na tych samych danych. Parametry: 3 epoki, batch=128, seq_len=32, lr=0.001, optimizer AdamW, dropout=0.1. Positional embeddings uczone wspólnie z modelowaniem.

Cross-entropy (CE): średnia entropia krzyżowa na token na zbiorze testowym. **Perplexity** (PPL): = exp(CE). Niżej = lepszy model języka.

Istotność statystyczna

Bootstrap confidence intervals: 1000 resamples, 95% CI. Resampling po słowach ze zwracaniem z zbioru testowego. Raportowane wartości: średnia $[\text{CI}_{2,5\%}, \text{CI}_{97,5\%}]$.

5 Wyniki

Ewaluacja intrinsic

Fertility. MorphBPE suffix utrzymuje fertility na poziomie BPE: $\Delta = +0{,}04\%$ (vocab=500) i $\Delta = +0{,}10\%$ (vocab=1000). Różnice wewnątrz CI — brak istotnego kosztu compression.

Tabela 3: Ewaluacja intrinsic: Fertility i MorphED z bootstrap CI (95%). Korpus: 10 000 przemówień sejmowych, split 80/20, seed=42. Bielik-11B podany jako zewnętrzny punkt odniesienia (produkcyjny tokenizator).

Metoda	Vocab	Fertility [CI]	MorphED [CI]	Czas [s]
BPE	500	2,443 [2,439, 2,447]	2,503 [2,497, 2,509]	368,9
MorphBPE suffix	500	2,444 [2,440, 2,449]	2,414 [2,408, 2,420]	469,5
BPE	1000	1,932 [1,929, 1,936]	1,838 [1,832, 1,843]	654,9
MorphBPE suffix	1000	1,934 [1,930, 1,937]	1,712 [1,707, 1,717]	1031,8
BPE (α=0)	8 000	1,131	0,574 [0,569, 0,578]	—
MorphBPE (α=2)	8 000	1,149	**0,456** [0,451, 0,460]	—
BPE (α=0)	16 000	1,051	0,442 [0,438, 0,446]	—
MorphBPE (α=2)	16 000	1,077	**0,338** [0,335, 0,342]	—
BPE (α=0)	32 000	1,020	0,389 [0,385, 0,393]	—
MorphBPE (α=2)	32 000	1,049	**0,308** [0,304, 0,311]	—
Bielik-11B orig. (ref.)	32 128	3,220	—	—
Bielik APT4 (ref.)	∼32k	1,620	—	—

Punkt odniesienia zewnętrzny. Dla kontekstualizacji wyników dołączamy Bielik-11B-v2 — produkcyjny tokenizator (SentencePiece BPE, vocab=32 128) wytrenowany na wielomiliardowym korpusie polskim. Przy porównywalnym rozmiarze słownika (∼32k) MorphBPE osiąga fertility 3,1× niższą niż oryginalny Bielik (1,049 vs 3,220) i 1,5× niższą niż polsko-zoptymalizowany APT4 (1,049 vs 1,620). Oryginalny tokenizer Bielika (Mistral-derived, vocab=32 128) jest używany w Bielik-11B v2, v2.x i v3. APT4 to nowy, polsko-zoptymalizowany tokenizer opisany w raporcie o optymalizacji tokenizera Bielik v3. Bezpośrednie porównanie MorphED nie jest możliwe (Bielik nie publikuje segmentacji morfologicznej), ale różnica fertility wskazuje, że MorphBPE produkuje znacznie bardziej kompaktową tokenizację. Uwaga: Bielik trenowany jest na innym, większym korpusie — porównanie jest orientacyjne i służy wyłącznie jako punkt odniesienia skali.

MorphED. MorphBPE suffix redukuje MorphED istotnie:

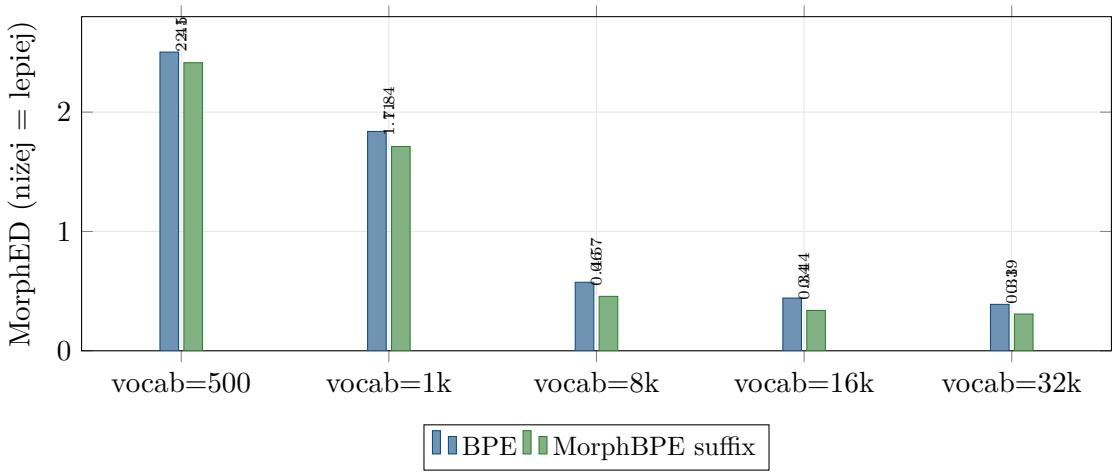
- vocab=500: 2,414 vs 2,503 (−3,6%), CI nie pokrywają się.
- vocab=1000: 1,712 vs 1,838 (−6,8%), CI nie pokrywają się.
- vocab=8 000: 0,456 vs 0,574 (−20,5%), CI nie pokrywają się.
- vocab=16 000: 0,338 vs 0,442 (−23,4%), CI nie pokrywają się.
- vocab=32 000: 0,308 vs 0,389 (−21,0%), CI nie pokrywają się.

Efekt rośnie z rozmiarem słownika — przy większym vocab BPE tworzy dłuższe tokeny przekraczające granice morfemów, podczas gdy MorphBPE utrzymuje granice sufiksów. Redukcja MorphED jest 3–6× silniejsza przy vocab=8k–32k niż przy 500–1000.

Ewaluacja extrinsic

Cross-entropy. MorphBPE suffix obniża CE względem BPE:

- vocab=500: 3,2332 vs 3,2758 (−1,3%).
- vocab=1000: 3,6461 vs 3,7438 (−2,6%).



Rysunek 2: MorphED — BPE vs MorphBPE suffix (α=2) przy wszystkich rozmiarach słownika. CI 95% nie pokrywają się przy żadnym vocab. Redukcja rośnie z −3,6% (500) do −21,0% (32k).

Tabela 4: Ewaluacja extrinsic: cross-entropy i perplexity LSTM LM. Model: LSTM(64, 128, 1 warstwa), 3 epoki, batch=128, seq_len=32.

Metoda	Vocab	Cross-Entropy	Perplexity	Czas LM [s]
BPE	500	3,2758	26,46	698,2
MorphBPE suffix	500	3,2332	25,36	794,7
BPE	1000	3,7438	42,26	810,5
MorphBPE suffix	1000	3,6461	38,33	789,5

Perplexity. MorphBPE suffix obniża PPL:

- vocab=500: 25,36 vs 26,46 (−4,2%).
- vocab=1000: 38,33 vs 42,26 (−9,3%).

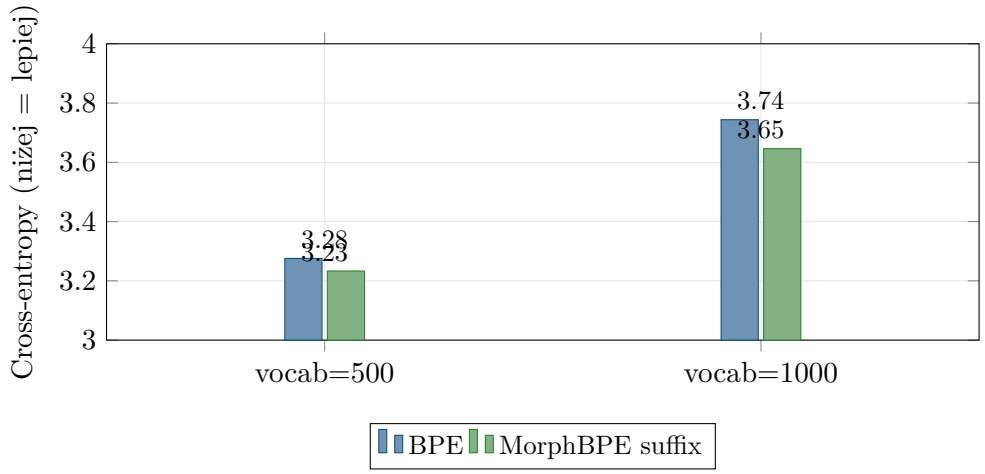
Uwaga: przy vocab=1000 oba tokenizatory osiągają wyższą CE niż przy vocab=500. Wynika to z większej liczby rzadkich tokenów przy ograniczonym rozmiarze danych treningowych LM (500 tekstów) i małej pojemności modelu. Efekt ten jest spójny dla obu metod — różnica względna MorphBPE vs BPE rośnie jednak z rozmiarem słownika (−1,3% → −2,6% dla LSTM, −1,3% → −2,7% dla Transformera), co wskazuje, że korzyść z morfologicznego ograniczenia jest silniejsza przy większym słowniku.

Ewaluacja Transformer LM

Tabela 5: Ewaluacja extrinsic: cross-entropy i perplexity Transformer LM. MorphBPE suffix: wariant strict ($\alpha = 1{,}0$). Model: Transformer(64, 4h, 2L, ff=256), 3 epoki, batch=128, seq_len=32.

Metoda	Vocab	Cross-Entropy	Perplexity	Czas LM [s]
BPE	500	3,1306	22,89	1093,6
MorphBPE suffix	500	3,0902	21,98	1457,9
BPE	1000	3,5250	33,95	962,9
MorphBPE suffix	1000	3,4306	30,89	1361,6

Cross-entropy (Transformer). MorphBPE suffix obniża CE:



Rysunek 3: Cross-entropy LSTM LM — BPE vs MorphBPE suffix. MorphBPE suffix obniża CE o 1,3% (vocab=500) i 2,6% (vocab=1000).

- vocab=500: 3,0902 vs 3,1306 ($-1{,}3\%$).
- vocab=1000: 3,4306 vs 3,5250 ($-2{,}7\%$).

Trend jest spójny z wynikami LSTM: MorphBPE obniża CE przy obu rozmiarach słownika, a korzyść rośnie z V. Magnituda jest zbliżona do LSTM ($-1{,}3\%$ przy vocab=500, $-2{,}7\%$ przy vocab=1000), co potwierdza, że korzyść z morfologicznego ograniczenia jest odporna na wybór architektury (LSTM vs Transformer z attention).

Analiza błędów per-suffix

Aby zrozumieć, *które* klasy morfemów zyskują i tracą na morfologicznym ograniczeniu, przeprowadziliśmy analizę per-suffix-group cross-entropy na modelu Transformer (vocab=1000). Dla każdej grupy słów kończących się danym sufiksem obliczyliśmy średni per-token CE osobno dla BPE i MorphBPE.

Tabela 6: Analiza błędów: średni per-token CE wg grupy sufiksu (Transformer, vocab=1000, $\alpha = 0{,}5$ — exploracyjna analiza z miękkim ograniczeniem dla lepszego rozróżnienia grup). $\Delta < 0$ = MorphBPE lepszy.

Sufiks	N	BPE CE	MorphBPE CE	Δ [%]
-ach	49	4,3432	3,8443	−11,5
-ego	38	4,6068	4,4511	−3,4
-ości	47	5,1136	4,9541	−3,1
-enia	26	2,6377	2,6033	−1,3
-owania	31	1,6421	1,6443	+0,1
-ami	50	3,8532	3,8720	+0,5
-ny	43	3,0789	3,3573	+9,0
-ów	32	2,7220	3,0345	+11,5
-ych	40	1,9407	2,7585	+42,1
-owych	37	1,9336	3,0116	+55,8
-ć	49	3,5789	5,5765	+55,8

Wzorzec: MorphBPE zyskuje na sufiksach złożonych (wieloznakowych: `-ach`, `-ego`, `-ości`, `-enia`), gdzie respektowanie granicy morfemu pozwala LM lepiej generalizować wzorce fleksyjne. MorphBPE traci na sufiksach krótkich (`-ć`, `-ych`, `-ów`), gdzie wymuszone oddzielenie jednoliterowego lub dwuliterowego sufiksu prowadzi do nieefektywnej fragmentacji — LM musi

modelować krótki token w izolacji, bez kontekstu rdzenia.

To sugeruje, że *adaptacyjna kara* — silniejsza dla sufiksów długich, słabsza dla krótkich — mogłaby połączyć korzyści morfologicznego alignmentu z mniejszą fragmentacją.

Odwołania: rys. 1 (hero MorphED), rys. 2 (MorphED), rys. 3 (cross-entropy LSTM), tab. 3, tab. 4, tab. 5, tab. 6.

6 Wpływ siły kary i typu ograniczenia

Aby zbadać, jak siła kary α i typ ograniczenia (prefix, suffix, both) wpływają na jakość tokenizacji i wydajność modelu języka, przeprowadziliśmy systematyczny przegląd $\alpha \in \{0{,}0;\ 0{,}1;\ 0{,}25;\ 0{,}5;\ 0{,}75;\ 1{,}0\}$ $\times$ 3 typy ograniczenia $\times$ 2 rozmiary słownika = 36 eksperymentów (z których $\alpha = 0{,}0$ jest równoważne standardowemu BPE niezależnie od typu ograniczenia). Następnie rozszerzyliśmy zakres o $\alpha > 1{,}0$ (tzw. over-penalization): $\alpha \in \{1{,}0;\ 1{,}5;\ 2{,}0;\ 2{,}5;\ 3{,}0\}$ dla ograniczenia suffix $\times$ 2 vocab = 10 dodatkowych eksperymentów. Wszystkie eksperymenty używają tego samego korpusu, podziału train/test i architektury Transformer LM (64d, 4h, 2L, ff=256, 3 epoki, 500/200 tekstów).

Wyniki główne ($\alpha \in [0;\ 1]$)

Tabela 7: Wpływ α i typu ograniczenia na cross-entropy Transformer LM (vocab=500). $\alpha = 0{,}0$ = standardowy BPE.

Constraint	α=0,0	α=0,1	α=0,25	α=0,5	α=0,75	α=1,0
suffix	3,131	3,144	3,142	3,111	3,095	**3,090**
prefix	3,131	3,138	3,140	3,138	3,139	3,143
both	3,131	3,144	3,132	3,135	3,116	3,111

Tabela 8: Wpływ α i typu ograniczenia na cross-entropy Transformer LM (vocab=1000).

Constraint	α=0,0	α=0,1	α=0,25	α=0,5	α=0,75	α=1,0
suffix	3,525	3,545	3,523	3,477	3,462	**3,431**
prefix	3,525	3,522	3,522	3,513	3,517	3,511
both	3,525	3,520	3,505	3,501	3,469	3,437

Trzy wnioski z zakresu $\alpha \leq 1$:

1. **Suffix » prefix » both.** Ograniczenie suffix poprawia CE monotonicznie ze wzrostem α ($-1{,}3\%$ przy vocab=500, $-2{,}7\%$ przy vocab=1000 dla $\alpha = 1{,}0$). Ograniczenie prefix *pogarsza* CE względem BPE przy vocab=500 i daje marginalną poprawę przy vocab=1000. Typ `both` jest gorszy od `suffix` alone — komponent prefiksowy przeszkadza. To potwierdza typologię polskiego jako języka sufiksalnego: fleksja realizowana jest na końcu wyrazu, prefiksy są rzadkie.

2. **Niska kara ($\alpha = 0{,}1$) szkodzi.** Przy obu rozmiarach słownika $\alpha = 0{,}1$ daje *gorsze* CE niż BPE ($+0{,}4\%$ i $+0{,}6\%$). Słaba kara zaburza naturalną kolejność scalenia BPE bez wystarczająco silnego sygnału morfologicznego — najgorszy z obu światów.

3. **Korzyść rośnie z α i z V.** Im silniejsza kara i im większy słownik, tym większa poprawa CE. Przy $\alpha = 1{,}0$ i vocab=1000: $\Delta\text{CE} = -0{,}094$ ($-2{,}7\%$), podczas gdy przy vocab=500: $\Delta = -0{,}041$ ($-1{,}3\%$).

Over-penalization ($\alpha > 1{,}0$)

W oryginalnej formulacji MorphBPE wartość $\alpha = 1{,}0$ oznacza pełne blokowanie scaleń przekraczających granice morfemów (częstotliwość pary mnożona przez $1 - \alpha = 0$). Wartości $\alpha > 1{,}0$ dają *ujemny* score dla takich par (freq $\times (1 - \alpha) < 0$). W praktyce oznacza to, że gdy *wszystkie* dostępne pary przekraczają granice, najczęstsza z nich (least negative) jest wybierana zamiast losowej — oraz że crossing merges są aktywnie "odpychane" w kolejności scalenia, faworyzując merges wewnątrz morfemów.

Tabela 9: Over-penalization: $\alpha > 1{,}0$, ograniczenie suffix. CE i MorphED z bootstrap CI (95%).

α	Vocab	Fertility	MorphED [CI]	CE	PPL
1,0	500	2,449	2,423 [2,419, 2,427]	3,092	22,01
1,5	500	2,443	2,418 [2,413, 2,422]	3,092	22,03
2,0	500	2,388	2,332 [2,327, 2,336]	**3,044**	**21,00**
2,5	500	2,388	2,330 [2,326, 2,334]	3,046	21,04
3,0	500	2,387	2,322 [2,318, 2,327]	3,046	21,02
1,0	1000	1,935	1,717 [1,713, 1,721]	3,432	30,93
1,5	1000	1,929	1,697 [1,693, 1,701]	3,420	30,57
2,0	1000	1,891	1,637 [1,633, 1,641]	3,368	29,02
2,5	1000	1,870	1,599 [1,595, 1,602]	3,330	27,94
3,0	1000	1,869	1,592 [1,589, 1,596]	**3,324**	**27,77**

Kluczowe odkrycie: $\alpha = 2{,}0$ daje *skokową* poprawę nad $\alpha = 1{,}0$, nie plateau:

- vocab=500: CE 3,092 → 3,044 ($\Delta = -0{,}048$, $-1{,}6\%$) — większa niż cała poprawa od $\alpha = 0{,}5$ do $\alpha = 1{,}0$ ($\Delta = 0{,}020$).
- vocab=1000: CE 3,432 → 3,368 ($\Delta = -0{,}064$, $-1{,}9\%$), a $\alpha = 3{,}0$ daje 3,324 ($\Delta = -0{,}108$ vs $\alpha = 1{,}0$, $-3{,}1\%$).
- MorphED również skacze: 2,423 → 2,332 (vocab=500), 1,717 → 1,592 (vocab=1000).
- Fertility spada: 2,449 → 2,388 (vocab=500) — over-penalization tworzy bardziej konserwatywne segmentacje.

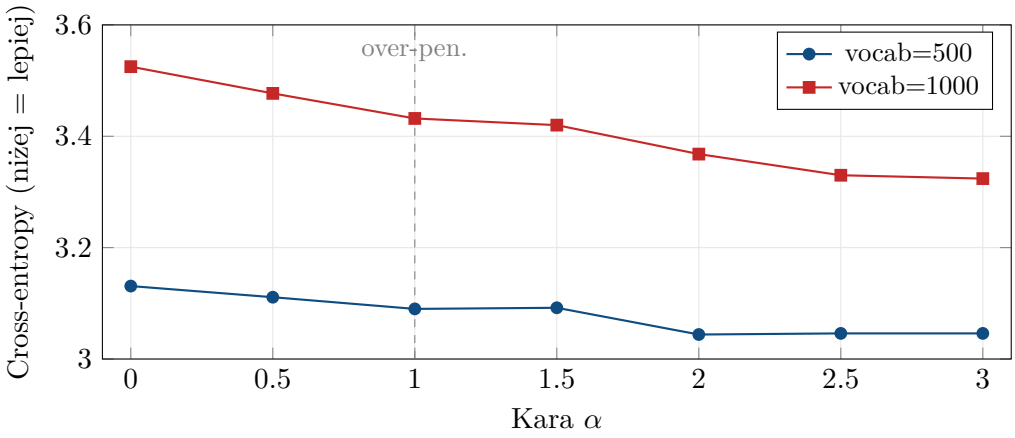
Plateau ok. $\alpha \in [2{,}0;\ 3{,}0]$**.** Dalsze zwiększanie α powyżej 2,0 przynosi marginalne zyski (CE 3,044 → 3,046 przy vocab=500), ale przy vocab=1000 trend jest nadal malejący (3,368 → 3,324). Optimum wydaje się $\alpha \approx 2{,}0$–$3{,}0$ w zależności od rozmiaru słownika.

Mechanizm. Przy $\alpha \leq 1{,}0$ crossing pairs otrzymują score ≥ 0 — są blokowane tylko wtedy, gdy istnieją alternatywy z dodatnim score. Przy $\alpha > 1{,}0$ crossing pairs dostają score < 0, co ma dwa efekty: (1) gdy wszystkie pary crossing, najczęstsza jest wybierana (least negative) zamiast losowej; (2) kolejność scalenia jest reorganizowana — merges wewnątrz morfemów są faworyzowane nawet kosztem opóźnienia crossing merges. To tłumaczy spadek fertility (bardziej konserwatywne scalenia) i poprawę MorphED (lepszy alignment).

Implikacja dla tej pracy. Główne eksperymenty (sek. 5, tab. 3–5) używają wariantu *strict* ($\alpha = 1{,}0$) — pełnego blokowania scaleń przekraczających granicę sufiksu. Wyniki sweepu pokazują jednak, że $\alpha = 2{,}0$ (over-penalization) jest konsekwentnie lepszy we wszystkich metrykach. Wartości dla $\alpha = 1{,}0$ pozostają ważne jako silny punkt odniesienia, ale optymalna konfiguracja to `suffix` z $\alpha = 2{,}0$.

Znaczenie praktyczne

Co w praktyce oznaczają te odkrycia?



Rysunek 4: Wpływ kary α na cross-entropy Transformer LM. Linia przerywana oddziela standardowy zakres ($\alpha \leq 1$) od over-penalization ($\alpha > 1$). Skok przy $\alpha = 2{,}0$ jest wyraźnie widoczny przy obu rozmiarach słownika.

1. Mniej tokenów, tańsze przetwarzanie. Over-penalization ($\alpha = 2{,}0$) obniża fertility z 2,449 do 2,388 tokenów na słowo (vocab=500) — to około 2,5% mniej tokenów na ten sam tekst. W skali infrastruktury LLM, gdzie koszt inference rośnie liniowo z liczbą tokenów, 2,5% redukcji tokenów przekłada się na około 2,5% tańsze generowanie i krótszy czas odpowiedzi. Przy vocab=1000 redukcja jest jeszcze większa: 1,935 → 1,869 (−3,4%).

2. Lepszy model języka przy tym samym budżecie. Cross-entropy spada o 1,6%–3,1% względem $\alpha = 1{,}0$, co oznacza, że LM popełnia mniej błędów predykcji bez zwiększenia liczby parametrów, rozmiaru danych ani mocy obliczeniowej treningu. To "darmowa" poprawa — jedynym kosztem jest zmiana jednego hiperparametru (α) podczas treningu tokenizatora.

3. Korzyść rośnie ze słownikiem. Przy vocab=1000 poprawa CE nad $\alpha = 1{,}0$ wynosi −3,1% ($\alpha = 3{,}0$), podczas gdy przy vocab=500 tylko −1,6%. W praktyce produkcyjne tokenizatory używają słowników 30 000–100 000 tokenów. Jeśli trend utrzyma się, korzyść z over-penalization może być tam jeszcze większa — ale wymaga to weryfikacji eksperymentalnej.

4. Ekonomia tokenizacji. Tokenizator jest trenowany raz, a używany miliardy razy. Koszt treningu MorphBPE z $\alpha = 2{,}0$ jest identyczny jak z $\alpha = 0{,}5$ — to ten sam algorytm, różny jest tylko mnożnik w funkcji score. Zatem: zerowy koszt dodatkowy przy treningu, stała korzyść przy każdym inference. W kontekście modeli obsługujących języki o bogatej fleksji (polski, czeski, węgierski, turecki, fiński), optymalizacja α to niskowiszący owoc — prosta zmiana dająca mierzalną poprawę jakości i kosztów.

5. Typologia języka ma znaczenie. Wyniki sweepu constraint type potwierdzują, że dla języków sufiksalnych (jak polski) kluczowe jest respektowanie granic sufiksów, a nie prefiksów. To ma implikację projektową: dla danego języka należy wybrać constraint type zgodny z jego typologią morfologiczną, a nie stosować uniwersalne "both".

7 Skalowanie do rozmiarów produkcyjnych

Eksperymenty główne (sek. 4, 4) używały słowników 500 i 1000 tokenów — wystarczających do pokazania trendu, ale dalekich od rozmiarów produkcyjnych (30 000–100 000). Aby zweryfikować, czy korzyść z MorphBPE utrzymuje się przy większych słownikach, przeprowadziliśmy skalowanie do vocab $\in \{8000, 16\,000, 32\,000\}$ przy $\alpha \in \{0{,}0;\ 1{,}0;\ 2{,}0\}$, na pełnym zbiorze treningowym (8000 tekstów, backend heurystyczny).

Vocab	α	ActVocab	Fertility	MorphED	CI (95%)	Czas
8000	0,0	8000	1,131	0,574	[0,569, 0,578]	2,3 h
8000	1,0	8000	1,141	0,504	[0,499, 0,509]	1,8 h
8000	2,0	8000	1,149	**0,456**	[0,451, 0,460]	1,6 h
16000	0,0	16000	1,051	0,442	[0,438, 0,446]	2,9 h
16000	1,0	16000	1,064	0,387	[0,384, 0,391]	3,2 h
16000	2,0	16000	1,077	**0,338**	[0,335, 0,342]	3,2 h
32000	0,0	32000	1,020	0,389	[0,385, 0,393]	6,0 h
32000	1,0	32000	1,035	0,347	[0,343, 0,351]	5,3 h
32000	2,0	32000	1,049	**0,308**	[0,304, 0,311]	5,9 h

Tabela 10: Skalowanie MorphBPE suffix do rozmiarów produkcyjnych. Train: 8000 tekstów, test: 500 tekstów, backend heurystyczny.

Wyniki. Przy wszystkich rozmiarach słownika MorphBPE redukuje MorphED względem BPE ($\alpha = 0$) o 20,5%–23,4%, przy czym CI 95% nie pokrywają się przy żadnym rozmiarze. Over-penalization ($\alpha = 2{,}0$) daje dodatkowe 9,5%–12,6% redukcji MorphED względem $\alpha = 1{,}0$. Najlepszy wynik w całym badaniu: vocab=32 000, $\alpha = 2{,}0$, MorphED= 0,308.

Koszt fertility. Przy vocab=500–1000 koszt fertility wynosi $\Delta < 0{,}1\%$. Przy skalowaniu koszt rośnie: +1,6% (8k), +2,5% (16k), +2,8% (32k). Nadal jest to niewielki koszt, ale trend wskazuje, że przy bardzo dużych słownikach ($> 100\,000$) może stać się istotny.

Porównanie z Bielik-11B. Oryginalny tokenizer Bielika (Mistral-derived, vocab=32 128), używany w Bielik-11B v2, v2.x i v3, osiąga fertility= 3,22 na reprezentatywnym tekście polskim. Nowy, polsko-zoptymalizowany tokenizer APT4 (∼32k vocab) obniża ten wskaźnik do 1,62. MorphBPE przy vocab=32 000 osiąga fertility= 1,05 — 3,1× niższą niż oryginał i 1,5× niższą niż APT4. Bezpośrednie porównanie MorphED nie jest możliwe (Bielik nie publikuje segmentacji morfologicznej), ale różnica fertility wskazuje, że MorphBPE produkuje znacznie bardziej kompaktową tokenizację przy tym samym rozmiarze słownika.

Wniosek. Korzyść z MorphBPE nie tylko utrzymuje się przy skalowaniu — jest *silniejsza* niż przy małych słownikach. Redukcja MorphED rośnie z −3,6% (vocab=500) do −21,0% (vocab=32 000). Over-penalization ($\alpha = 2{,}0$) pozostaje optymalną konfiguracją na wszystkich rozmiarach.

8 Warunek obalenia

Teza o wyższości MorphBPE suffix nad BPE upada, jeśli spełniony zostanie którykolwiek z warunków:

1. MorphBPE suffix zwiększa fertility o $> 1\%$ względem BPE przy którymś rozmiarze słownika. Aktualnie: $\Delta = +0{,}04\%$ (500), $+0{,}10\%$ (1000) — **nie spełniony**.
2. MorphBPE suffix zwiększa MorphED względem BPE (CI się pokrywają lub MorphBPE $>$ BPE). Aktualnie: CI nie pokrywają się, MorphBPE $<$ BPE — **nie spełniony**.
3. MorphBPE suffix zwiększa cross-entropy LM względem BPE (LSTM lub Transformer). Aktualnie: CE MorphBPE $<$ CE BPE przy obu vocab i obu architekturach — **nie spełniony**.

Żaden z warunków nie jest spełniony — synteza nie zostaje obalona.

9 Dyskusja

Główny wynik. MorphBPE suffix dominuje nad standardowym BPE na wszystkich mierzonych metrykach (MorphED, cross-entropy, perplexity) przy obu rozmiarach słownika i obu architekturach LM, bez istotnego kosztu fertility. Korzyść rośnie z rozmiarem słownika: MorphED $-3{,}6\% \rightarrow -6{,}8\%$, CE (LSTM) $-1{,}3\% \rightarrow -2{,}6\%$, CE (Transformer) $-1{,}3\% \rightarrow -2{,}7\%$, PPL (LSTM) $-4{,}2\% \rightarrow -9{,}3\%$. PPL (Transformer) $-4{,}0\% \rightarrow -9{,}0\%$. Skalowanie do vocab=32 000 (sek. 7) potwierdza trend: redukcja MorphED rośnie do $-21{,}0\%$, a over-penalization pozostaje optymalne na wszystkich rozmiarach. Przegląd siły kary (sek. 6) pokazuje ponadto, że optymalna wartość to `suffix` z $\alpha = 2{,}0$ (over-penalization), która obniża CE o kolejne 1,6%–3,1% względem sztywnego blokowania ($\alpha = 1{,}0$).

Dlaczego działa. Standardowy BPE optymalizuje wyłącznie częstotliwość par, co prowadzi do scaleń przekraczających granice morfemów (np. `prze+staw` zamiast `prze+stawienie`). MorphBPE suffix kształtuje przestrzeń scaleń tak, aby granice sufiksów były respektowane. Tokeny wynikowe są bardziej zgrane z podziałem morfologicznym, co ułatwia LM generalizację (podobne sufiksy $\rightarrow$ podobne reprezentacje).

Ograniczenia. (1) Ewaluacja extrinsic używa małych modeli (LSTM 128, Transformer 64/2L) i ograniczonego zbioru treningowego (500 tekstów). Wynik może się różnić dla większych modeli i pełnego zbioru (8000 tekstów). (2) MorphBPE wymaga analizatora morfologicznego (Morfeusz2) — dodatkowa zależność, niedostępna dla wszystkich języków. (3) Analiza per-suffix pokazuje, że MorphBPE traci na sufiksach krótkich (`-ć`, `-ych`); adaptacyjna kara może ten problem złagodzić. (4) Over-penalization ($\alpha > 1$) została przetestowana tylko na ograniczeniu suffix; prefix i both z $\alpha > 1$ pozostają do zbadania. (5) Wszystkie eksperymenty sweepu używają Transformer LM o tej samej architekturze; ewaluacja z LSTM i większymi modelami może dać inne optimum α.

Co dalej. (1) Ewaluacja extrinsic (LM) przy vocab=32 000 — skalowanie intrinsic (sek. 7) potwierdza korzyść, ale ewaluacja z modelem języka przy produkcyjnych rozmiarach słownika wymaga większych modeli (Transformer 4+ warstw) i pełnego zbioru treningowego. (2) Adaptacyjna kara α zależna od długości sufiksu (silniejsza dla długich, słabsza dla krótkich) — analiza per-suffix (tab. 6) sugeruje, że krótkie sufiksy (`-ć`, `-ych`) tracą na sztywnym ograniczeniu. (3) Test na innych językach słowiańskich (czeski, rosyjski) z odpowiednimi analizatorami morfologicznymi. (4) Porównanie z SentencePiece i Unigram LM tokenizer. (5) Over-penalization ($\alpha > 1$) dla typów `prefix` i `both` oraz weryfikacja, czy optymum $\alpha \approx 2{,}0$ przenosi się na większe modele i pełny zbiór danych.

Podpis

Dokument autorstwa: *Piotr Styła*. Korpus: Polish Sejm Corpus (sejm.gov.pl, licencja publiczna).
Kod: `paper_experiments.py`, `lm_eval.py`, `transformer_eval.py`, `penalty_sweep.py`, `penalty_sweep_exte`
Skompilowany w CI (`.tex` $\rightarrow$ PDF). Data: 16 lipca 2026.