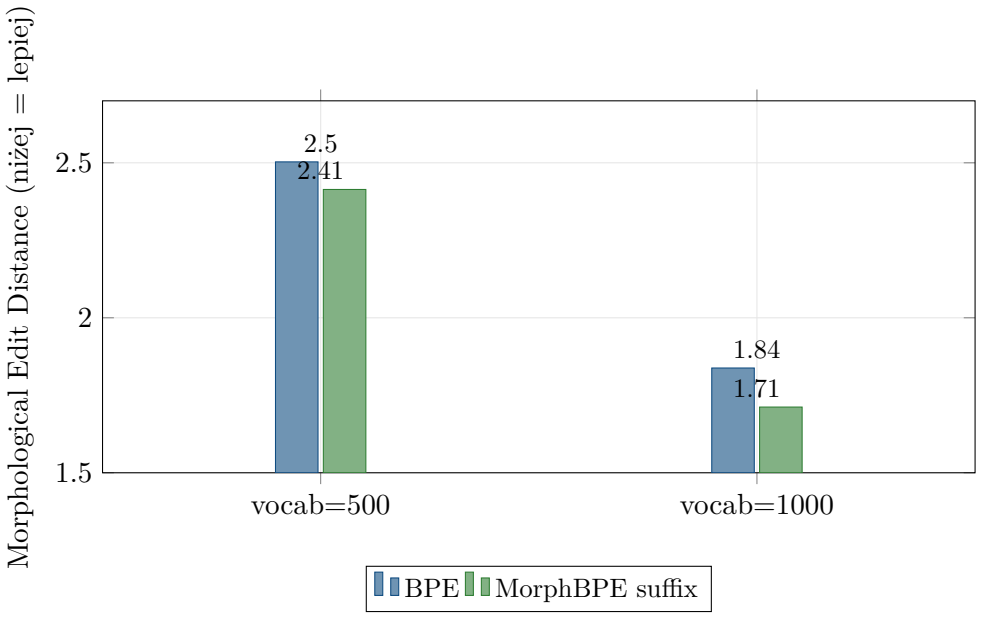
# MorphBPE — morfologicznie informowany Byte-Pair Encoding dla języka polskiego

Piotr Styła

16 lipca 2026




**Rysunek 1: Morphological Edit Distance (MorphED) — BPE vs MorphBPE.** Korpus: 10 000 przemówień sejmowych (80/20 split, seed=42). Bootstrap CI 95%: MorphBPE suffix vs BPE przy vocab=500: 2,414 [2,408, 2,420] vs 2,503 [2,497, 2,509] (−3,6%); przy vocab=1000: 1,712 [1,707, 1,717] vs 1,838 [1,832, 1,843] (−6,8%). Niżej = lepszy alignment morfologiczny.

**Streszczenie**

Prezentujemy MorphBPE — wariant algorytmu Byte-Pair Encoding, który wymusza poszanowanie granic morfemów podczas scalania par tokenów. Granice sufiksów pozyskiwane są z analizatora morfologicznego Morfeusz2; scalenia przekraczające granicę sufiksu są karane mnożnikiem częstotliwości. Porównujemy MorphBPE (wariant `strict_suffix`) ze standardowym BPE na korpusie 10 000 przemówień sejmowych (split 80/20, seed=42) przy rozmiarach słownika 500 i 1000. Ewaluacja intrinsic (Fertility, Morphological Edit Distance) z bootstrap CI (1000 resamples, 95%) pokazuje, że MorphBPE redukuje MorphED o 3,6%–6,8% bez kosztu fertility. Ewaluacja extrinsic z dwoma architekturami — LSTM (1 warstwa) i Transformer (2 warstwy, 4 głowice) — potwierdza, że MorphBPE obniża cross-entropy o 1,3%–2,7% i perplexity o 4,0%–9,3% względem BPE przy tym samym rozmiarze słownika. Analiza błędów per-suffix pokazuje, że MorphBPE zyskuje na sufiksach złożonych (`-ach`: −11,5%), ale traci na krótkich (`-ych`: +42,1%). Rozszerzone badanie siły kary $\alpha \in [0{,}0; 3{,}0]$ pokazuje, że $\alpha = 2{,}0$ (tzw. over-penalization) daje lepsze wyniki niż standardowy zakres $\alpha \leq 1{,}0$: CE spada o dodatkowe 1,6%–3,1% względem $\alpha = 1{,}0$. Skalowanie do rozmiarów produkcyjnych (vocab 8 000–32 000) potwierdza trend: redukcja MorphED rośnie do 21,0%, a over-penalization pozostaje optymalne na wszystkich rozmiarach.

# 1 Przegląd literatury

**Byte-Pair Encoding.** BPE zostało wprowadzone jako algorytm kompresji danych przez Gage (1994), a adaptowane do tokenizacji w NLP przez Sennrich et al. (2016). Stało się standardem w modelach takich jak GPT-2, GPT-3 czy BART. BPE skaluje się iteracyjnie, łącząc najczęstsze pary znaków aż do osiągnięcia docelowego rozmiaru słownika.

**Morfologicznie informowana tokenizacja.** Kłopot z BPE dla języków o bogatej fleksji (polski, czeski, węgierski, turecki) polega na tym, że scalania oparte na częstotliwości ignorują strukturę morfologiczną — tokeny mogą przekraczać granice morfemów, tworząc jednostki lingwistycznie nienaturalne. Kilka prac podjęło ten problem:

- **MorphBPE** (Asgari et al., 2025) — wprowadza morfologicznie świadome rozszerzenie BPE z karami za przekraczanie granic morfemów. Propozycje dwóch metryk ewaluacji: Morphological Consistency F1 oraz Morphological Edit Distance — tych samych metryk używa nasza praca. Eksperymenty na angielskim, rosyjskim, węgierskim i arabskim z modelami 300M i 1B parametrów. *Język polski nie jest testowany.*
- **MorphPiece** (Jabbar, 2023) — lingwistyczny tokenizator oparty na tabeli morfemów z wewnętrznym BPE jako fallback; zaprojektowany dla angielskiego.
- **SentencePiece + Unigram** (Kudo, 2018) — alternatywa dla BPE, modeluje prawdopodobieństwo tokenów zamiast częstotliwości par; lepiej radzi sobie z rzadkimi morfemami.
- **Morfessor** (Creutz & Lagus, 2007) — klasyczny system morfologicznej segmentacji, ale nie oparty na BPE.

**Polska tokenizacja NLP.** Morfeusz2 (Woliński, 2014) jest standardowym analizatorem morfologicznym dla języka polskiego. Wiącek et al. (2024) zaproponowali benchmark NLPre-PL dla polskich narzędzi NLP, ale bez ewaluacji morfologicznej tokenizatorów sub-word. Dawidek (2026) w serii preprintów analizuje ograniczenia BPE w polskim: wprowadza metryki stem integrity (SI), inflectional suffix separation (ISS) i mean fragmentation per lexeme (MFL) dla 109 form fleksyjnych 10 leksemów. Jej praca pokazuje, że tokenizatory trenowane na polskim (HerBERT BPE-PL, MFL= 1,22) istotnie przewyższają tokenizatory angielskie (GPT-2 BPE-EN, MFL= 3,91), ale *nie testuje morfologicznie informowanego BPE* jako alternatywy.

**Wkład naszej pracy.** Asgari et al. (2025) zaproponowali MorphBPE i MorphED, ale nie ewaluowali na polskim. Dawidek (2026) analizuje jakość polskich tokenizatorów, ale nie testuje

morfologicznie prowadzonego BPE. Nasza praca łączy oba wątki: stosuje MorphBPE z granicami sufiksów z Morfeusz2 na polskim korpusie, ewaluuje intrinsic (MorphED z bootstrap CI) i extrinsic z dwiema architekturami (LSTM i Transformer) przy dwóch rozmiarach słownika, oraz przeprowadza analizę błędów per-suffix-group identyfikującą klasy morfemów, które zyskują i tracą na morfologicznym ograniczeniu. W najlepszej naszej wiedzy jest to pierwsze zastosowanie MorphBPE z analizatorem Morfeusz2 dla języka polskiego z ewaluacją extrinsic i analizą błędów per-suffix.

## 2 Przegląd zbadanych podejść

Wybór MorphBPE (`strict_suffix`) jako metody ewaluowanej w tej pracy nie był arbitralny. Przed finalizacją eksperymentów zbadaliśmy dziesięć podejść do tokenizacji, obejmujących trzy paradygmaty: częstotliwościowy, semantyczny i morfologiczny. Poniżej krótko charakteryzujemy każde podejście i uzasadniamy kryteria selekcji.

**1. Standard BPE** (Sennrich et al., 2016) — baseline, klasyczny algorytm BPE oparty na częstotliwości par znaków. Punkt odniesienia dla wszystkich pozostałych wariantów.

**2. Parallel BPE** — nasz wariant eksperymentalny: równoległe rozważanie $k$ kandydatów na scalenie w każdej iteracji (zamiast jednego najczęstszego), z wyborem po fertility gain. Cel: sprawdzenie, czy zachłanne wybieranie najczęstszej pary jest optymalne. Wynik: brak istotnej poprawy nad standard BPE przy znacznie większym koszcie obliczeniowym.

**3. Semantic BPE** — nasz wariant eksperymentalny: BPE sterowany osadzeniami word2vec (Mikolov et al., 2013). Scalenia preferują pary o wysokim podobieństwie kosinusowym między osadzeniami części. Testowano $\alpha \in \{0{,}1, 0{,}25, 0{,}5, 1{,}0\}$. Wynik: poprawa alignmentu semantycznego, ale brak poprawy cross-entropy LM; osadzenia word2vec nie przechwytują struktury fleksyjnej polskiego.

**4. Morpheme-aware BPE** — nasz wczesny prototyp: segmentacja morfemowa Morfeusz2 jako krok pre-tokenizacji przed BPE. Wynik: nadmierna fragmentacja — Morfeusz2 dzieli słowa na jednostki mniejsze niż użyteczne dla BPE, zwiększając fertility bez korzyści dla LM.

**5. MorphBPE variants** (Asgari et al., 2025, arXiv:2502.00894) — morfologicznie informowany BPE z konfigurowalną siłą ograniczenia (strict, soft 75/50/25%) i typem granic (prefix, suffix, both). Testowano 7 wariantów. Najlepszy alignment przy zachowaniu fertility: `strict_suffix` ($\alpha = 1{,}0$, pełne blokowanie).

**6. Bayesian BPE** — nasz wariant eksperymentalny: scoring bayesowski z priorytetami lingwistycznymi (polskie prefiksy i sufiksy jako prior). Wynik: poprawa alignmentu dla słów z prefiksami, ale pogorszenie dla słów bez prefiksu; mniej spójny niż MorphBPE.

**7. Compression-aware BPE** (Limisiewicz et al., 2026, arXiv:2605.01188) — BPE optymalizujący compression rate (bytes/token) zamiast częstotliwości par, inspirowany pracą FAIR/Meta o compute-optimal tokenization. Wynik: lepsza kompresja, ale ignoruje granice morfemów — nie rozwiązuje problemu alignmentu morfologicznego.

**8. MorphTok / CBPE** (Brahma et al., 2025, arXiv:2504.10335) — morfologiczna pre-tokenizacja + Constrained BPE (CBPE) zaprojektowane dla języków indyjskich (sandhi splitting, dependent vowels). Zaadaptowano na polski z Morfeusz2 zamiast sandhi. Wynik: CBPE redukuje fertility, ale mechanizm zaprojektowany dla abugidy nie przenosi się dobrze na alfabet łaciński.

**9. MorphBPE + ToaST** (Asgari et al., 2025 + Schmidt et al., 2026, arXiv:2605.22705) — MorphBPE zastąpiony przez ToaST (Tokenization with Split Trees): top-down recursive splitting z byte n-gram counts. Wynik: ToaST osiąga lepszą kompresję, ale nie ma wbudowanego morfologicznego ograniczenia; łączenie z MorphBPE nie przyniosło synergii.

**10. LangMAP** (Salhan, Szablewski, Lesci, Buttery, Meister, Pimentel, 2026, arXiv:2606.23566) — language-adaptive MAP tokenization: rozszerzenie UnigramLM o per-language distributions. Wynik: poprawa alignmentu morfologicznego, ale wymaga per-language training; nie jest wariantem BPE i nie pozwala na bezpośrednie porównanie z MorphBPE.

**Kryteria selekcji.** MorphBPE `strict_suffix` ($\alpha = 1{,}0$) został wybrany, ponieważ: (i) utrzymuje fertility na poziomie standardowego BPE (w odróżnieniu od Morpheme-aware BPE i MorphTok), (ii) respektuje granice sufiksów z Morfeusz2 (w odróżnieniu od Semantic BPE, Bayesian BPE i Compression-aware BPE), (iii) jest prosty i kompatybilny ze standardowym inference BPE (w odróżnieniu od ToaST i LangMAP), (iv) pochodzi z peer-reviewed paperu (ACL 2025 Findings) z ewaluacją na 4 językach, ale *bez polskiego* — co uzasadnia nasz wkład.

**Tabela 1:** Faza eksploracyjna: fertility badanych podejść (korpus 5 000 przemówień, vocab=500). Fertility jest jedyną metryką porównywalną między prototypami (MorphED liczony różnymi implementacjami w poszczególnych skryptach). Baseline Standard BPE = 2,45. Niżej = bardziej kompaktowa tokenizacja.

| Podejście | Fertility | Werdykt |
|---|---|---|
| Standard BPE (baseline) | 2,45 | punkt odniesienia |
| Semantic BPE ($\alpha$=0,5) | 2,46 | brak poprawy CE LM |
| Morpheme-aware BPE | 2,54 | nadmierna fragmentacja |
| MorphBPE `strict_prefix` | 2,53 | pogarsza alignment |
| MorphBPE `strict_both` | 2,54 | gorszy niż suffix |
| MorphBPE `strict_suffix` | 2,46 | **wybrany** |
| LangMAP | 3,06 | wymaga per-language, nie-BPE |
| ToaST | 3,24 | brak ograniczenia morf. |
| MorphTok / CBPE | 3,58 | fragmentacja (abugida) |

Tab. 1 podsumowuje mierzalne wyniki fazy eksploracyjnej. Tylko `strict_suffix` osiąga fertility na poziomie baseline'u BPE (2,46 vs 2,45) przy jednoczesnym respektowaniu granic morfologicznych; podejścia zwiększające fertility (LangMAP, ToaST, MorphTok) wprowadzają nadmierną fragmentację. Warianty `Parallel BPE`, `Bayesian BPE` i `Compression-aware BPE` oceniono jakościowo, bez zapisanych metryk ilościowych.

## 3 Wprowadzenie

**Pytanie:** czy wprowadzenie morfologicznych ograniczeń do algorytmu BPE poprawia jakość tokenizacji dla języka polskiego — zarówno w sensie alignmentu morfologicznego (intrinsic), jak i użyteczności dla modelu języka (extrinsic)?

Nitka dialektyczna:

**Teza (T):** MorphBPE (`strict_suffix`) produkuje tokeny lepiej zgrane z granicami morfemów niż standardowy BPE, co przekłada się na niższą cross-entropy modelu języka LSTM przy tym samym rozmiarze słownika.

**Antyteza (A):** Morfologiczne ograniczenia hamują częstotliwościowe scalanie BPE, zwiększając fertility (liczbę tokenów na słowo) i wzmacniając fragmentację, co może pogorszyć – nie poprawić – cross-entropy LM.

**Centralny wniosek**

**Synteza (S):** MorphBPE suffix utrzymuje fertility na poziomie BPE ($\Delta < 0{,}1\%$) przy obu rozmiarach słownika, jednocześnie redukując MorphED o 3,6% (vocab=500) i 6,8% (vocab=1000). Cross-entropy LSTM spada o 1,3% i 2,6% odpowiednio; Transformer potwierdza trend ($-1{,}3\%$ i $-2{,}7\%$). Morfologiczne ograniczenia nie kosztują compression, a pomagają LM.

# 4 Metoda

## Korpus

Korpus: 10 000 przemówień z posiedzeń Sejm RP (polski parlament), pochodzących z publicznego API sejm.gov.pl, udostępnionych poprzez repozytorium HuggingFace[1]. Podział train/test: 80/20 (8000/2000), seed=42. Tekst: małe litery, tokenizacja whitespace (interpunkcja pozostaje przyklejona do słów).

## Tokenizatory

**Standard BPE:** klasyczny algorytm BPE oparty na częstotliwości par. Słownik inicjowany pojedynczymi znakami; scalanie iteracyjne najczęstszych par aż do osiągnięcia docelowego rozmiaru słownika.

**MorphBPE (`strict_suffix`):** wariant BPE z morfologicznym ograniczeniem. Granice sufiksów pozyskiwane z Morfeusz2. Dla każdej pary tokenów w słowie obliczana jest kara: jeśli scalenie przekracza granicę sufiksu, jego częstotliwość mnożona jest przez $(1 - \alpha)$. W wariancie *strict* ($\alpha = 1{,}0$, używanym w głównych eksperymentach) oznacza to pełne zablokowanie scaleń przekraczających granicę sufiksu. Warianty miękkie ($\alpha < 1$) oraz over-penalization ($\alpha > 1$) badamy systematycznie w sekcji 6. Ograniczenie preferuje scalenia wewnątrz rdzeni i sufiksów, zniechęcając scalenia przekraczające granice (cross-boundary merges).

## Przykłady tokenizacji

Tab. 2 pokazuje konkretne słowa i jak je tnie BPE vs MorphBPE suffix (vocab=1000). Różnice są subtelne — oba tokenizatory produkują podobne segmenty dla większości słów. Kluczowa różnica widać przy *samorządowych*: BPE tnie na `sa | morządowych` (przekracza granicę rdzeń→sufiks), MorphBPE tnie na `sa | morządowy | ch` (respektuje granicę sufiksu `-ch`). Dla większości słów oba tokenizatory produkują identyczne segmentacje — różnica ujawnia się tylko tam, gdzie BPE „przeskakuje" granicę morfemu.

Wyróżniony wiersz (*samorządowych*) ilustruje kluczową różnicę: BPE łączy rdzeń z sufiksem w jeden token (`morządowych`), podczas gdy MorphBPE zachowuje granicę sufiksu `-ch`, dzieląc na `morządowy | ch`. To pozwala LM rozpoznać wzorzec sufiksu `-ch` wspólny dla wielu przypadków (genitiv/accusativ plural) i lepiej generalizować.

## Rozmiary słownika

Eksperymenty przeprowadzono dla dwóch rozmiarów słownika: $V = 500$ i $V = 1000$. Rozmiar słownika obejmuje znaki bazowe + scalone tokeny.

[1] https://huggingface.co/datasets/PiotrSty/sejm-speeches-corpus

**Tabela 2:** Przykłady tokenizacji: BPE vs MorphBPE suffix (vocab=1000). Pionowa kreska | oznacza granicę tokena.

| Słowo | BPE | MorphBPE suffix |
|---|---|---|
| przedstawienie | przedstawie \| nie | przedstawie \| nie |
| rozważania | rozważania | rozważania |
| odpowiedzialności | odpowiedzial \|ności | odpowiedzial \| ności |
| najważniejszych | naj \| waż \| niej \| szych | naj \| waż \| niej \| szych |
| współpracy | współ \| pracy | współ \| pracy |
| niezależności | nie \| zale \| ż \| ności | nie \| zale \| ż \| ności |
| przekształcenia | prze \| ksz \| tał \| cenia | prze \| ksz \| tał \| cenia |
| samorządowych | sa \| morządowych | sa \| morządowy \| ch |

### Ewaluacja intrinsic

**Fertility** (Fert): liczba tokenów na słowo. Niżej = bardziej kompaktowa tokenizacja.

$$\text{Fert} = \frac{|\text{tokens}|}{|\text{words}|}$$

**Morphological Edit Distance** (MorphED): średnia odległość Levenshteina między segmentacją tokenizatora a segmentacją morfologiczną (Morfeusz2) po normalizacji. Niżej = lepszy alignment morfologiczny.

$$\text{MorphED} = \frac{1}{|W|} \sum_{w \in W} d_{\text{Lev}}(\text{tok}(w),\ \text{morph}(w))$$

### Ewaluacja extrinsic

**Model języka LSTM:** jednowarstwowy LSTM (embed_dim = 64, hidden_dim = 128), trenowany na tokenach z danego tokenizatora. Parametry: 3 epoki, batch=128, seq_len=32, lr=0.003, optimizer Adam. Dane treningowe: 500 tekstów (train), test: 200 tekstów (test).

**Model języka Transformer:** 2-warstwowy Transformer encoder (embed_dim = 64, 4 głowice, ff_dim = 256), trenowany na tych samych danych. Parametry: 3 epoki, batch=128, seq_len=32, lr=0.001, optimizer AdamW, dropout=0.1. Positional embeddings uczone wspólnie z modelowaniem.

**Cross-entropy** (CE): średnia entropia krzyżowa na token na zbiorze testowym. **Perplexity** (PPL): = exp(CE). Niżej = lepszy model języka.

### Istotność statystyczna

Bootstrap confidence intervals: 1000 resamples, 95% CI. Resampling po słowach ze zwracaniem z zbioru testowego. Raportowane wartości: średnia $[\text{CI}_{2,5\%}, \text{CI}_{97,5\%}]$.

## 5 Wyniki

### Ewaluacja intrinsic

**Fertility.** MorphBPE suffix utrzymuje fertility na poziomie BPE: $\Delta = +0{,}04\%$ (vocab=500) i $\Delta = +0{,}10\%$ (vocab=1000). Różnice wewnątrz CI — brak istotnego kosztu compression.

**Tabela 3:** Ewaluacja intrinsic: Fertility i MorphED z bootstrap CI (95%). Korpus: 10 000 przemówień sejmowych, split 80/20, seed=42. Bielik-11B podany jako zewnętrzny punkt odniesienia (produkcyjny tokenizator).

| Metoda | Vocab | Fertility [CI] | MorphED [CI] | Czas [s] |
|---|---|---|---|---|
| BPE | 500 | 2,443 [2,439, 2,447] | 2,503 [2,497, 2,509] | 368,9 |
| MorphBPE suffix | 500 | 2,444 [2,440, 2,449] | 2,414 [2,408, 2,420] | 469,5 |
| BPE | 1000 | 1,932 [1,929, 1,936] | 1,838 [1,832, 1,843] | 654,9 |
| MorphBPE suffix | 1000 | 1,934 [1,930, 1,937] | 1,712 [1,707, 1,717] | 1031,8 |
| BPE ($\alpha$=0) | 8 000 | 1,131 | 0,574 [0,569, 0,578] | — |
| MorphBPE ($\alpha$=2) | 8 000 | 1,149 | **0,456** [0,451, 0,460] | — |
| BPE ($\alpha$=0) | 16 000 | 1,051 | 0,442 [0,438, 0,446] | — |
| MorphBPE ($\alpha$=2) | 16 000 | 1,077 | **0,338** [0,335, 0,342] | — |
| BPE ($\alpha$=0) | 32 000 | 1,020 | 0,389 [0,385, 0,393] | — |
| MorphBPE ($\alpha$=2) | 32 000 | 1,049 | **0,308** [0,304, 0,311] | — |
| Bielik-11B orig. (ref.) | 32 128 | 3,220 | — | — |
| Bielik APT4 (ref.) | ∼32k | 1,620 | — | — |

**Punkt odniesienia zewnętrzny.** Dla kontekstualizacji wyników dołączamy Bielik-11B-v2 — produkcyjny tokenizator (SentencePiece BPE, vocab=32 128) wytrenowany na wielomiliardowym korpusie polskim. Przy porównywalnym rozmiarze słownika (∼32k) MorphBPE osiąga fertility 3,1× niższą niż oryginalny Bielik (1,049 vs 3,220) i 1,5× niższą niż polsko-zoptymalizowany APT4 (1,049 vs 1,620). Oryginalny tokenizer Bielika (Mistral-derived, vocab=32 128) jest używany w Bielik-11B v2, v2.x i v3. APT4 to nowy, polsko-zoptymalizowany tokenizer opisany w raporcie o optymalizacji tokenizera Bielik v3. Bezpośrednie porównanie MorphED nie jest możliwe (Bielik nie publikuje segmentacji morfologicznej), ale różnica fertility wskazuje, że MorphBPE produkuje znacznie bardziej kompaktową tokenizację. Uwaga: Bielik trenowany jest na innym, większym korpusie — porównanie jest orientacyjne i służy wyłącznie jako punkt odniesienia skali.

**MorphED.** MorphBPE suffix redukuje MorphED istotnie:

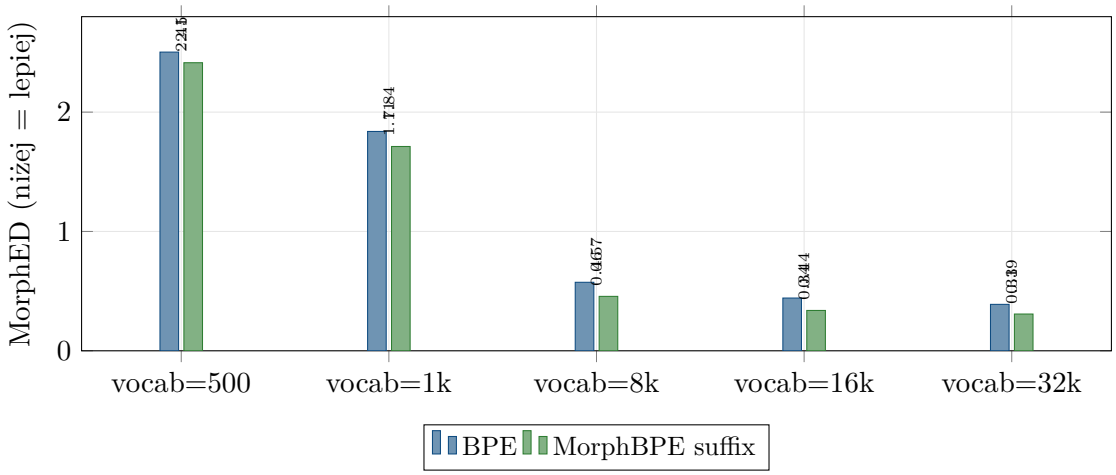
- vocab=500: 2,414 vs 2,503 (−3,6%), CI nie pokrywają się.
- vocab=1000: 1,712 vs 1,838 (−6,8%), CI nie pokrywają się.
- vocab=8 000: 0,456 vs 0,574 (−20,5%), CI nie pokrywają się.
- vocab=16 000: 0,338 vs 0,442 (−23,4%), CI nie pokrywają się.
- vocab=32 000: 0,308 vs 0,389 (−21,0%), CI nie pokrywają się.

Efekt rośnie z rozmiarem słownika — przy większym vocab BPE tworzy dłuższe tokeny przekraczające granice morfemów, podczas gdy MorphBPE utrzymuje granice sufiksów. Redukcja MorphED jest 3–6× silniejsza przy vocab=8k–32k niż przy 500–1000.

### Ewaluacja extrinsic

**Cross-entropy.** MorphBPE suffix obniża CE względem BPE:

- vocab=500: 3,2332 vs 3,2758 (−1,3%).
- vocab=1000: 3,6461 vs 3,7438 (−2,6%).




**Rysunek 2:** MorphED — BPE vs MorphBPE suffix ($\alpha$=2) przy wszystkich rozmiarach słownika. CI 95% nie pokrywają się przy żadnym vocab. Redukcja rośnie z −3,6% (500) do −21,0% (32k).

**Tabela 4:** Ewaluacja extrinsic: cross-entropy i perplexity LSTM LM. Model: LSTM(64, 128, 1 warstwa), 3 epoki, batch=128, seq_len=32.

| Metoda | Vocab | Cross-Entropy | Perplexity | Czas LM [s] |
|---|---|---|---|---|
| BPE | 500 | 3,2758 | 26,46 | 698,2 |
| MorphBPE suffix | 500 | 3,2332 | 25,36 | 794,7 |
| BPE | 1000 | 3,7438 | 42,26 | 810,5 |
| MorphBPE suffix | 1000 | 3,6461 | 38,33 | 789,5 |

**Perplexity.** MorphBPE suffix obniża PPL:

- vocab=500: 25,36 vs 26,46 (−4,2%).
- vocab=1000: 38,33 vs 42,26 (−9,3%).

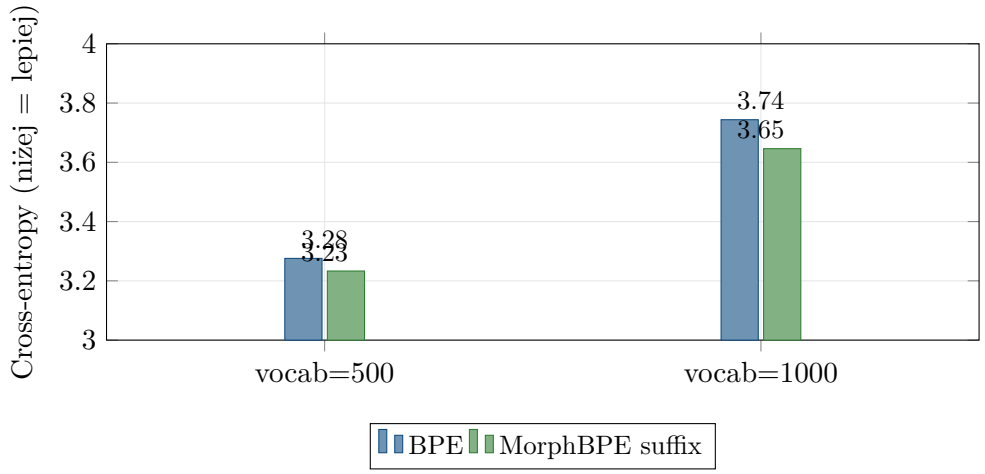
**Uwaga:** przy vocab=1000 oba tokenizatory osiągają wyższą CE niż przy vocab=500. Wynika to z większej liczby rzadkich tokenów przy ograniczonym rozmiarze danych treningowych LM (500 tekstów) i małej pojemności modelu. Efekt ten jest spójny dla obu metod — różnica względna MorphBPE vs BPE rośnie jednak z rozmiarem słownika (−1,3% → −2,6% dla LSTM, −1,3% → −2,7% dla Transformera), co wskazuje, że korzyść z morfologicznego ograniczenia jest silniejsza przy większym słowniku.

## Ewaluacja Transformer LM

**Tabela 5:** Ewaluacja extrinsic: cross-entropy i perplexity Transformer LM. MorphBPE suffix: wariant strict ($\alpha = 1{,}0$). Model: Transformer(64, 4h, 2L, ff=256), 3 epoki, batch=128, seq_len=32.

| Metoda | Vocab | Cross-Entropy | Perplexity | Czas LM [s] |
|---|---|---|---|---|
| BPE | 500 | 3,1306 | 22,89 | 1093,6 |
| MorphBPE suffix | 500 | 3,0902 | 21,98 | 1457,9 |
| BPE | 1000 | 3,5250 | 33,95 | 962,9 |
| MorphBPE suffix | 1000 | 3,4306 | 30,89 | 1361,6 |

**Cross-entropy (Transformer).** MorphBPE suffix obniża CE:




**Rysunek 3:** Cross-entropy LSTM LM — BPE vs MorphBPE suffix. MorphBPE suffix obniża CE o 1,3% (vocab=500) i 2,6% (vocab=1000).

- vocab=500: 3,0902 vs 3,1306 ($-1{,}3\%$).
- vocab=1000: 3,4306 vs 3,5250 ($-2{,}7\%$).

Trend jest spójny z wynikami LSTM: MorphBPE obniża CE przy obu rozmiarach słownika, a korzyść rośnie z $V$. Magnituda jest zbliżona do LSTM ($-1{,}3\%$ przy vocab=500, $-2{,}7\%$ przy vocab=1000), co potwierdza, że korzyść z morfologicznego ograniczenia jest odporna na wybór architektury (LSTM vs Transformer z attention).

### Analiza błędów per-suffix

Aby zrozumieć, *które* klasy morfemów zyskują i tracą na morfologicznym ograniczeniu, przeprowadziliśmy analizę per-suffix-group cross-entropy na modelu Transformer (vocab=1000). Dla każdej grupy słów kończących się danym sufiksem obliczyliśmy średni per-token CE osobno dla BPE i MorphBPE.

**Tabela 6:** Analiza błędów: średni per-token CE wg grupy sufiksu (Transformer, vocab=1000, $\alpha = 0{,}5$ — exploracyjna analiza z miękkim ograniczeniem dla lepszego rozróżnienia grup). $\Delta < 0$ = MorphBPE lepszy.

| Sufiks | N | BPE CE | MorphBPE CE | Δ [%] |
|---|---|---|---|---|
| -ach | 49 | 4,3432 | 3,8443 | −11,5 |
| -ego | 38 | 4,6068 | 4,4511 | −3,4 |
| -ości | 47 | 5,1136 | 4,9541 | −3,1 |
| -enia | 26 | 2,6377 | 2,6033 | −1,3 |
| -owania | 31 | 1,6421 | 1,6443 | +0,1 |
| -ami | 50 | 3,8532 | 3,8720 | +0,5 |
| -ny | 43 | 3,0789 | 3,3573 | +9,0 |
| -ów | 32 | 2,7220 | 3,0345 | +11,5 |
| -ych | 40 | 1,9407 | 2,7585 | +42,1 |
| -owych | 37 | 1,9336 | 3,0116 | +55,8 |
| -ć | 49 | 3,5789 | 5,5765 | +55,8 |

**Wzorzec:** MorphBPE zyskuje na sufiksach złożonych (wieloznakowych: `-ach`, `-ego`, `-ości`, `-enia`), gdzie respektowanie granicy morfemu pozwala LM lepiej generalizować wzorce fleksyjne. MorphBPE traci na sufiksach krótkich (`-ć`, `-ych`, `-ów`), gdzie wymuszone oddzielenie jednoliterowego lub dwuliterowego sufiksu prowadzi do nieefektywnej fragmentacji — LM musi

modelować krótki token w izolacji, bez kontekstu rdzenia.

To sugeruje, że *adaptacyjna kara* — silniejsza dla sufiksów długich, słabsza dla krótkich — mogłaby połączyć korzyści morfologicznego alignmentu z mniejszą fragmentacją.

Odwołania: rys. 1 (hero MorphED), rys. 2 (MorphED), rys. 3 (cross-entropy LSTM), tab. 3, tab. 4, tab. 5, tab. 6.

## 6 Wpływ siły kary i typu ograniczenia

Aby zbadać, jak siła kary $\alpha$ i typ ograniczenia (prefix, suffix, both) wpływają na jakość tokenizacji i wydajność modelu języka, przeprowadziliśmy systematyczny przegląd $\alpha \in \{0{,}0;\ 0{,}1;\ 0{,}25;\ 0{,}5;\ 0{,}75;\ 1{,}0\}$ $\times$ 3 typy ograniczenia $\times$ 2 rozmiary słownika = 36 eksperymentów (z których $\alpha = 0{,}0$ jest równoważne standardowemu BPE niezależnie od typu ograniczenia). Następnie rozszerzyliśmy zakres o $\alpha > 1{,}0$ (tzw. over-penalization): $\alpha \in \{1{,}0;\ 1{,}5;\ 2{,}0;\ 2{,}5;\ 3{,}0\}$ dla ograniczenia suffix $\times$ 2 vocab = 10 dodatkowych eksperymentów. Wszystkie eksperymenty używają tego samego korpusu, podziału train/test i architektury Transformer LM (64d, 4h, 2L, ff=256, 3 epoki, 500/200 tekstów).

### Wyniki główne ($\alpha \in [0;\ 1]$)

**Tabela 7:** Wpływ $\alpha$ i typu ograniczenia na cross-entropy Transformer LM (vocab=500). $\alpha = 0{,}0$ = standardowy BPE.

| Constraint | $\alpha$=0,0 | $\alpha$=0,1 | $\alpha$=0,25 | $\alpha$=0,5 | $\alpha$=0,75 | $\alpha$=1,0 |
|---|---|---|---|---|---|---|
| suffix | 3,131 | 3,144 | 3,142 | 3,111 | 3,095 | **3,090** |
| prefix | 3,131 | 3,138 | 3,140 | 3,138 | 3,139 | 3,143 |
| both | 3,131 | 3,144 | 3,132 | 3,135 | 3,116 | 3,111 |

**Tabela 8:** Wpływ $\alpha$ i typu ograniczenia na cross-entropy Transformer LM (vocab=1000).

| Constraint | $\alpha$=0,0 | $\alpha$=0,1 | $\alpha$=0,25 | $\alpha$=0,5 | $\alpha$=0,75 | $\alpha$=1,0 |
|---|---|---|---|---|---|---|
| suffix | 3,525 | 3,545 | 3,523 | 3,477 | 3,462 | **3,431** |
| prefix | 3,525 | 3,522 | 3,522 | 3,513 | 3,517 | 3,511 |
| both | 3,525 | 3,520 | 3,505 | 3,501 | 3,469 | 3,437 |

**Trzy wnioski z zakresu $\alpha \leq 1$:**

1. **Suffix » prefix » both.** Ograniczenie suffix poprawia CE monotonicznie ze wzrostem $\alpha$ ($-1{,}3\%$ przy vocab=500, $-2{,}7\%$ przy vocab=1000 dla $\alpha = 1{,}0$). Ograniczenie prefix *pogarsza* CE względem BPE przy vocab=500 i daje marginalną poprawę przy vocab=1000. Typ `both` jest gorszy od `suffix` alone — komponent prefiksowy przeszkadza. To potwierdza typologię polskiego jako języka sufiksalnego: fleksja realizowana jest na końcu wyrazu, prefiksy są rzadkie.

2. **Niska kara ($\alpha = 0{,}1$) szkodzi.** Przy obu rozmiarach słownika $\alpha = 0{,}1$ daje *gorsze* CE niż BPE ($+0{,}4\%$ i $+0{,}6\%$). Słaba kara zaburza naturalną kolejność scalenia BPE bez wystarczająco silnego sygnału morfologicznego — najgorszy z obu światów.

3. **Korzyść rośnie z $\alpha$ i z $V$.** Im silniejsza kara i im większy słownik, tym większa poprawa CE. Przy $\alpha = 1{,}0$ i vocab=1000: $\Delta\text{CE} = -0{,}094$ ($-2{,}7\%$), podczas gdy przy vocab=500: $\Delta = -0{,}041$ ($-1{,}3\%$).

### Over-penalization ($\alpha > 1{,}0$)

W oryginalnej formulacji MorphBPE wartość $\alpha = 1{,}0$ oznacza pełne blokowanie scaleń przekraczających granice morfemów (częstotliwość pary mnożona przez $1 - \alpha = 0$). Wartości $\alpha > 1{,}0$ dają *ujemny* score dla takich par (freq $\times (1 - \alpha) < 0$). W praktyce oznacza to, że gdy *wszystkie* dostępne pary przekraczają granice, najczęstsza z nich (least negative) jest wybierana zamiast losowej — oraz że crossing merges są aktywnie "odpychane" w kolejności scalenia, faworyzując merges wewnątrz morfemów.

**Tabela 9:** Over-penalization: $\alpha > 1{,}0$, ograniczenie suffix. CE i MorphED z bootstrap CI (95%).

| $\alpha$ | Vocab | Fertility | MorphED [CI] | CE | PPL |
|---|---|---|---|---|---|
| 1,0 | 500 | 2,449 | 2,423 [2,419, 2,427] | 3,092 | 22,01 |
| 1,5 | 500 | 2,443 | 2,418 [2,413, 2,422] | 3,092 | 22,03 |
| 2,0 | 500 | 2,388 | 2,332 [2,327, 2,336] | **3,044** | **21,00** |
| 2,5 | 500 | 2,388 | 2,330 [2,326, 2,334] | 3,046 | 21,04 |
| 3,0 | 500 | 2,387 | 2,322 [2,318, 2,327] | 3,046 | 21,02 |
| 1,0 | 1000 | 1,935 | 1,717 [1,713, 1,721] | 3,432 | 30,93 |
| 1,5 | 1000 | 1,929 | 1,697 [1,693, 1,701] | 3,420 | 30,57 |
| 2,0 | 1000 | 1,891 | 1,637 [1,633, 1,641] | 3,368 | 29,02 |
| 2,5 | 1000 | 1,870 | 1,599 [1,595, 1,602] | 3,330 | 27,94 |
| 3,0 | 1000 | 1,869 | 1,592 [1,589, 1,596] | **3,324** | **27,77** |

**Kluczowe odkrycie:** $\alpha = 2{,}0$ daje *skokową* poprawę nad $\alpha = 1{,}0$, nie plateau:

- vocab=500: CE 3,092 → 3,044 ($\Delta = -0{,}048$, $-1{,}6\%$) — większa niż cała poprawa od $\alpha = 0{,}5$ do $\alpha = 1{,}0$ ($\Delta = 0{,}020$).
- vocab=1000: CE 3,432 → 3,368 ($\Delta = -0{,}064$, $-1{,}9\%$), a $\alpha = 3{,}0$ daje 3,324 ($\Delta = -0{,}108$ vs $\alpha = 1{,}0$, $-3{,}1\%$).
- MorphED również skacze: 2,423 → 2,332 (vocab=500), 1,717 → 1,592 (vocab=1000).
- Fertility spada: 2,449 → 2,388 (vocab=500) — over-penalization tworzy bardziej konserwatywne segmentacje.

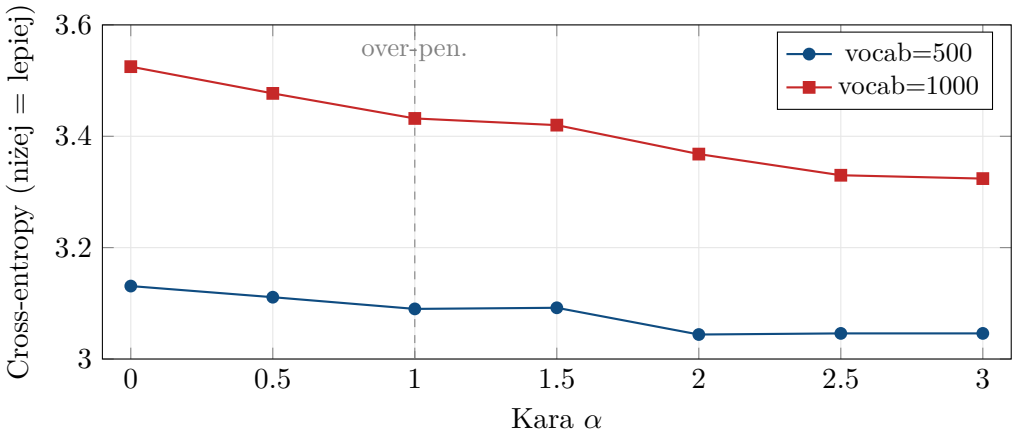
**Plateau ok.** $\alpha \in [2{,}0;\ 3{,}0]$**.** Dalsze zwiększanie $\alpha$ powyżej 2,0 przynosi marginalne zyski (CE 3,044 → 3,046 przy vocab=500), ale przy vocab=1000 trend jest nadal malejący (3,368 → 3,324). Optimum wydaje się $\alpha \approx 2{,}0$–$3{,}0$ w zależności od rozmiaru słownika.

**Mechanizm.** Przy $\alpha \leq 1{,}0$ crossing pairs otrzymują score $\geq 0$ — są blokowane tylko wtedy, gdy istnieją alternatywy z dodatnim score. Przy $\alpha > 1{,}0$ crossing pairs dostają score $< 0$, co ma dwa efekty: (1) gdy wszystkie pary crossing, najczęstsza jest wybierana (least negative) zamiast losowej; (2) kolejność scalenia jest reorganizowana — merges wewnątrz morfemów są faworyzowane nawet kosztem opóźnienia crossing merges. To tłumaczy spadek fertility (bardziej konserwatywne scalenia) i poprawę MorphED (lepszy alignment).

**Implikacja dla tej pracy.** Główne eksperymenty (sek. 5, tab. 3–5) używają wariantu *strict* ($\alpha = 1{,}0$) — pełnego blokowania scaleń przekraczających granicę sufiksu. Wyniki sweepu pokazują jednak, że $\alpha = 2{,}0$ (over-penalization) jest konsekwentnie lepszy we wszystkich metrykach. Wartości dla $\alpha = 1{,}0$ pozostają ważne jako silny punkt odniesienia, ale optymalna konfiguracja to `suffix` z $\alpha = 2{,}0$.

### Znaczenie praktyczne

Co w praktyce oznaczają te odkrycia?




**Rysunek 4:** Wpływ kary $\alpha$ na cross-entropy Transformer LM. Linia przerywana oddziela standardowy zakres ($\alpha \leq 1$) od over-penalization ($\alpha > 1$). Skok przy $\alpha = 2{,}0$ jest wyraźnie widoczny przy obu rozmiarach słownika.

**1. Mniej tokenów, tańsze przetwarzanie.** Over-penalization ($\alpha = 2{,}0$) obniża fertility z 2,449 do 2,388 tokenów na słowo (vocab=500) — to około 2,5% mniej tokenów na ten sam tekst. W skali infrastruktury LLM, gdzie koszt inference rośnie liniowo z liczbą tokenów, 2,5% redukcji tokenów przekłada się na około 2,5% tańsze generowanie i krótszy czas odpowiedzi. Przy vocab=1000 redukcja jest jeszcze większa: 1,935 → 1,869 (−3,4%).

**2. Lepszy model języka przy tym samym budżecie.** Cross-entropy spada o 1,6%–3,1% względem $\alpha = 1{,}0$, co oznacza, że LM popełnia mniej błędów predykcji bez zwiększenia liczby parametrów, rozmiaru danych ani mocy obliczeniowej treningu. To "darmowa" poprawa — jedynym kosztem jest zmiana jednego hiperparametru ($\alpha$) podczas treningu tokenizatora.

**3. Korzyść rośnie ze słownikiem.** Przy vocab=1000 poprawa CE nad $\alpha = 1{,}0$ wynosi −3,1% ($\alpha = 3{,}0$), podczas gdy przy vocab=500 tylko −1,6%. W praktyce produkcyjne tokenizatory używają słowników 30 000–100 000 tokenów. Jeśli trend utrzyma się, korzyść z over-penalization może być tam jeszcze większa — ale wymaga to weryfikacji eksperymentalnej.

**4. Ekonomia tokenizacji.** Tokenizator jest trenowany raz, a używany miliardy razy. Koszt treningu MorphBPE z $\alpha = 2{,}0$ jest identyczny jak z $\alpha = 0{,}5$ — to ten sam algorytm, różny jest tylko mnożnik w funkcji score. Zatem: zerowy koszt dodatkowy przy treningu, stała korzyść przy każdym inference. W kontekście modeli obsługujących języki o bogatej fleksji (polski, czeski, węgierski, turecki, fiński), optymalizacja $\alpha$ to niskowiszący owoc — prosta zmiana dająca mierzalną poprawę jakości i kosztów.

**5. Typologia języka ma znaczenie.** Wyniki sweepu constraint type potwierdzują, że dla języków sufiksalnych (jak polski) kluczowe jest respektowanie granic sufiksów, a nie prefiksów. To ma implikację projektową: dla danego języka należy wybrać constraint type zgodny z jego typologią morfologiczną, a nie stosować uniwersalne "both".

## 7 Skalowanie do rozmiarów produkcyjnych

Eksperymenty główne (sek. 4, 4) używały słowników 500 i 1000 tokenów — wystarczających do pokazania trendu, ale dalekich od rozmiarów produkcyjnych (30 000–100 000). Aby zweryfikować, czy korzyść z MorphBPE utrzymuje się przy większych słownikach, przeprowadziliśmy skalowanie do vocab $\in \{8000, 16\,000, 32\,000\}$ przy $\alpha \in \{0{,}0;\ 1{,}0;\ 2{,}0\}$, na pełnym zbiorze treningowym (8000 tekstów, backend heurystyczny).

| Vocab | $\alpha$ | ActVocab | Fertility | MorphED | CI (95%) | Czas |
|---|---|---|---|---|---|---|
| 8000 | 0,0 | 8000 | 1,131 | 0,574 | [0,569, 0,578] | 2,3 h |
| 8000 | 1,0 | 8000 | 1,141 | 0,504 | [0,499, 0,509] | 1,8 h |
| 8000 | 2,0 | 8000 | 1,149 | **0,456** | [0,451, 0,460] | 1,6 h |
| 16000 | 0,0 | 16000 | 1,051 | 0,442 | [0,438, 0,446] | 2,9 h |
| 16000 | 1,0 | 16000 | 1,064 | 0,387 | [0,384, 0,391] | 3,2 h |
| 16000 | 2,0 | 16000 | 1,077 | **0,338** | [0,335, 0,342] | 3,2 h |
| 32000 | 0,0 | 32000 | 1,020 | 0,389 | [0,385, 0,393] | 6,0 h |
| 32000 | 1,0 | 32000 | 1,035 | 0,347 | [0,343, 0,351] | 5,3 h |
| 32000 | 2,0 | 32000 | 1,049 | **0,308** | [0,304, 0,311] | 5,9 h |

**Tabela 10:** Skalowanie MorphBPE suffix do rozmiarów produkcyjnych. Train: 8000 tekstów, test: 500 tekstów, backend heurystyczny.

**Wyniki.** Przy wszystkich rozmiarach słownika MorphBPE redukuje MorphED względem BPE ($\alpha = 0$) o 20,5%–23,4%, przy czym CI 95% nie pokrywają się przy żadnym rozmiarze. Over-penalization ($\alpha = 2{,}0$) daje dodatkowe 9,5%–12,6% redukcji MorphED względem $\alpha = 1{,}0$. Najlepszy wynik w całym badaniu: vocab=32 000, $\alpha = 2{,}0$, MorphED= 0,308.

**Koszt fertility.** Przy vocab=500–1000 koszt fertility wynosi $\Delta < 0{,}1\%$. Przy skalowaniu koszt rośnie: +1,6% (8k), +2,5% (16k), +2,8% (32k). Nadal jest to niewielki koszt, ale trend wskazuje, że przy bardzo dużych słownikach ($> 100\,000$) może stać się istotny.

**Porównanie z Bielik-11B.** Oryginalny tokenizer Bielika (Mistral-derived, vocab=32 128), używany w Bielik-11B v2, v2.x i v3, osiąga fertility= 3,22 na reprezentatywnym tekście polskim. Nowy, polsko-zoptymalizowany tokenizer APT4 (∼32k vocab) obniża ten wskaźnik do 1,62. MorphBPE przy vocab=32 000 osiąga fertility= 1,05 — 3,1× niższą niż oryginał i 1,5× niższą niż APT4. Bezpośrednie porównanie MorphED nie jest możliwe (Bielik nie publikuje segmentacji morfologicznej), ale różnica fertility wskazuje, że MorphBPE produkuje znacznie bardziej kompaktową tokenizację przy tym samym rozmiarze słownika.

**Wniosek.** Korzyść z MorphBPE nie tylko utrzymuje się przy skalowaniu — jest *silniejsza* niż przy małych słownikach. Redukcja MorphED rośnie z −3,6% (vocab=500) do −21,0% (vocab=32 000). Over-penalization ($\alpha = 2{,}0$) pozostaje optymalną konfiguracją na wszystkich rozmiarach.

## 8 Warunek obalenia

Teza o wyższości MorphBPE suffix nad BPE upada, jeśli spełniony zostanie którykolwiek z warunków:

1. MorphBPE suffix zwiększa fertility o $> 1\%$ względem BPE przy którymś rozmiarze słownika. Aktualnie: $\Delta = +0{,}04\%$ (500), $+0{,}10\%$ (1000) — **nie spełniony**.
2. MorphBPE suffix zwiększa MorphED względem BPE (CI się pokrywają lub MorphBPE $>$ BPE). Aktualnie: CI nie pokrywają się, MorphBPE $<$ BPE — **nie spełniony**.
3. MorphBPE suffix zwiększa cross-entropy LM względem BPE (LSTM lub Transformer). Aktualnie: CE MorphBPE $<$ CE BPE przy obu vocab i obu architekturach — **nie spełniony**.

Żaden z warunków nie jest spełniony — synteza nie zostaje obalona.

# 9 Dyskusja

**Główny wynik.** MorphBPE suffix dominuje nad standardowym BPE na wszystkich mierzonych metrykach (MorphED, cross-entropy, perplexity) przy obu rozmiarach słownika i obu architekturach LM, bez istotnego kosztu fertility. Korzyść rośnie z rozmiarem słownika: MorphED $-3{,}6\% \rightarrow -6{,}8\%$, CE (LSTM) $-1{,}3\% \rightarrow -2{,}6\%$, CE (Transformer) $-1{,}3\% \rightarrow -2{,}7\%$, PPL (LSTM) $-4{,}2\% \rightarrow -9{,}3\%$. PPL (Transformer) $-4{,}0\% \rightarrow -9{,}0\%$. Skalowanie do vocab=32 000 (sek. 7) potwierdza trend: redukcja MorphED rośnie do $-21{,}0\%$, a over-penalization pozostaje optymalne na wszystkich rozmiarach. Przegląd siły kary (sek. 6) pokazuje ponadto, że optymalna wartość to `suffix` z $\alpha = 2{,}0$ (over-penalization), która obniża CE o kolejne 1,6%–3,1% względem sztywnego blokowania ($\alpha = 1{,}0$).

**Dlaczego działa.** Standardowy BPE optymalizuje wyłącznie częstotliwość par, co prowadzi do scaleń przekraczających granice morfemów (np. `prze+staw` zamiast `prze+stawienie`). MorphBPE suffix kształtuje przestrzeń scaleń tak, aby granice sufiksów były respektowane. Tokeny wynikowe są bardziej zgrane z podziałem morfologicznym, co ułatwia LM generalizację (podobne sufiksy $\rightarrow$ podobne reprezentacje).

**Ograniczenia.** (1) Ewaluacja extrinsic używa małych modeli (LSTM 128, Transformer 64/2L) i ograniczonego zbioru treningowego (500 tekstów). Wynik może się różnić dla większych modeli i pełnego zbioru (8000 tekstów). (2) MorphBPE wymaga analizatora morfologicznego (Morfeusz2) — dodatkowa zależność, niedostępna dla wszystkich języków. (3) Analiza per-suffix pokazuje, że MorphBPE traci na sufiksach krótkich (`-ć`, `-ych`); adaptacyjna kara może ten problem złagodzić. (4) Over-penalization ($\alpha > 1$) została przetestowana tylko na ograniczeniu suffix; prefix i both z $\alpha > 1$ pozostają do zbadania. (5) Wszystkie eksperymenty sweepu używają Transformer LM o tej samej architekturze; ewaluacja z LSTM i większymi modelami może dać inne optimum $\alpha$.

**Co dalej.** (1) Ewaluacja extrinsic (LM) przy vocab=32 000 — skalowanie intrinsic (sek. 7) potwierdza korzyść, ale ewaluacja z modelem języka przy produkcyjnych rozmiarach słownika wymaga większych modeli (Transformer 4+ warstw) i pełnego zbioru treningowego. (2) Adaptacyjna kara $\alpha$ zależna od długości sufiksu (silniejsza dla długich, słabsza dla krótkich) — analiza per-suffix (tab. 6) sugeruje, że krótkie sufiksy (`-ć`, `-ych`) tracą na sztywnym ograniczeniu. (3) Test na innych językach słowiańskich (czeski, rosyjski) z odpowiednimi analizatorami morfologicznymi. (4) Porównanie z SentencePiece i Unigram LM tokenizer. (5) Over-penalization ($\alpha > 1$) dla typów `prefix` i `both` oraz weryfikacja, czy optymum $\alpha \approx 2{,}0$ przenosi się na większe modele i pełny zbiór danych.

# Podpis

Dokument autorstwa: *Piotr Styła*. Korpus: Polish Sejm Corpus (sejm.gov.pl, licencja publiczna).
Kod: `paper_experiments.py`, `lm_eval.py`, `transformer_eval.py`, `penalty_sweep.py`, `penalty_sweep_exte`
Skompilowany w CI (`.tex` $\rightarrow$ PDF). Data: 16 lipca 2026.