MorphBPE

Morfologicznie informowany Byte-Pair Encoding
dla jezyka polskiego

Piotr Styla
Slayer AI Lab, 2026

MorphED - BPE vs MorphBPE (bootstrap CI 95%)

Vocab	BPE MorphED	MorphBPE MorphED	Redukcja
500	2.503 [2.497,2.509]	2.414 [2.408,2.420]	-3.6%
1000	1.838 [1.832,1.843]	1.712 [1.707,1.717]	-6.8%
8000	0.574 [0.569,0.578]	0.456 [0.451,0.460]	-20.5%
16000	0.442 [0.438,0.446]	0.338 [0.335,0.342]	-23.4%
32000	0.389 [0.385,0.393]	0.308 [0.304,0.311]	-21.0%

Korpus: 10 000 przemowien sejmowych (sejm.gov.pl)
Split 80/20, seed=42. Bootstrap: 1000 resamples, 95% CI.

Abstrakt

Prezentujemy MorphBPE - wariant algorytmu Byte-Pair Encoding, ktory wymusza poszanowanie granic morfemow podczas scalania par tokenow. Granice sufiksow pozyskiwane sa z analizatora morfologicznego Morfeusz2; scalenia przekraczajace granice sufiksu sa karane mnoznikiem czestotliwosci. Porownujemy MorphBPE (wariant strict_suffix) ze standardowym BPE na korpusie 10 000 przemowien sejmowych (split 80/20, seed=42) przy rozmiarach slownika 500 i 1000. Ewaluacja intrinsic (Fertility, Morphological Edit Distance) z bootstrap CI (1000 resamples, 95%) pokazuje, ze MorphBPE redukuje MorphED o 3,6%-6,8% bez kosztu fertility. Ewaluacja extrinsic z dwiema architekturami - LSTM (1 warstwa) i Transformer (2 warstwy, 4 glowice) - potwierdza, ze MorphBPE obniza cross-entropy o 1,3%-2,7% i perplexity o 4,0%-9,3% wzgledem BPE. Rozszerzone badanie sily kary alpha in [0,0; 3,0] pokazuje, ze alpha=2,0 (over-penalization) daje lepsze wyniki niz standardowy zakres: CE spada o dodatkowe 1,6%-3,1% wzgledem alpha=1,0.

Skalowanie do rozmiarow produkcyjnych (vocab 8 000-32 000) potwierdza trend: redukcja MorphED rosnie do 21,0%, a over-penalization pozostaje optymalne na wszystkich rozmiarach.

1. Przeglad literatury

Byte-Pair Encoding.

BPE wprowadzone jako algorytm kompresji (Gage, 1994), adaptowane do tokenizacji NLP przez Sennrich et al. (2016). Standard w GPT-2, GPT-3, BART.

MorphBPE

(Asgari et al., 2025) - morfologicznie swiadome BPE z karami za przekraczanie granic morfemow. Eksperymenty na angielskim, rosyjskim, wegierskim, arabskim.

Polski nie testowany.

MorfPiece

(Jabbar, 2023) - lingwistyczny tokenizator oparty na tabeli morfemow.

SentencePiece + Unigram

(Kudo, 2018) - modeluje prawdopodobieństwa tokenow.

Morfeusz2

(Wolinski, 2014) - standardowy analizator morfologiczny dla polskiego.

Dawidek (2026)

analizuje ograniczenia BPE w polskim: metryki SI, ISS, MFL dla 109 form fleksyjnych 10 leksemow. Nie testuje morfologicznie informowanego BPE.

Wklad naszej pracy:

(1) pierwsza ewaluacja MorphBPE na polskim z Morfeusz2, (2) over-penalization (alpha>1), (3) analiza bledow per-suffix, (4) ewaluacja z dwiema architekturami, (5)

skalowanie do rozmiarow produkcyjnych (32k)

.

2. Metoda

Korpus

10 000 przemowien z posiedzen Sejm RP (sejm.gov.pl), HuggingFace: PiotrSty/sejm-speeches-corpus. Split 80/20 (8000/2000), seed=42.

MorphBPE strict_suffix

Granice sufiksow z Morfeusz2. Scalenie przekraczajace granice: score = freq * (1 - alpha). alpha=0: standard BPE. alpha=1: pelne blokowanie. alpha>1: over-penalization (ujemny score).

Metryki

Fertility

= |tokens| / |words| (nizej = bardziej kompaktowo).

MorphED
= srednia odleglosc Levenshteina miedzy segmentacja tokenizatora a morfologiczna.
Bootstrap CI
: 1000 resamples, 95%.

3. Wyniki intrinsic

Metoda	Vocab	Fertility	MorphED [CI]	Redukcja
BPE	500	2.443	2.503 [2.497,2.509]	-
MorphBPE	500	2.444	2.414 [2.408,2.420]	-3.6%
BPE	1000	1.932	1.838 [1.832,1.843]	-
MorphBPE	1000	1.934	1.712 [1.707,1.717]	-6.8%

CI 95% nie pokrywaja sie przy obu rozmiarach slownika. Fertility bez kosztu (Delta < 0,1%).

4. Wyniki extrinsic

LSTM (1 warstwa, 64d/128h)

Metoda

BPE	500	3.276	26.46	-
MorphBPE	500	3.233	25.36	-1.3%
BPE	1000	3.744	42.26	-
MorphBPE	1000	3.646	38.33	-2.6%

Transformer (2 warstwy, 4 glowice, 64d)

Metoda

BPE	500	3.131	22.89	-
MorphBPE	500	3.090	21.98	-1.3%
BPE	1000	3.525	33.95	-
MorphBPE	1000	3.431	30.89	-2.7%

Trend spojny miedzy architekturami. Korzysc rosnie z rozmiarem slownika.

5. Over-penalization (alpha > 1)

alpha	Vocab	Fertility	MorphED [CI]	CE	PPL
1.0	500	2.449	2.423 [2.419,2.427]	3.092	22.01
2.0	500	2.388	2.332 [2.327,2.336]	3.044	21.00
3.0	500	2.387	2.322 [2.318,2.327]	3.046	21.02
1.0	1000	1.935	1.717 [1.713,1.721]	3.432	30.93
2.0	1000	1.891	1.637 [1.633,1.641]	3.368	29.02
3.0	1000	1.869	1.592 [1.589,1.596]	3.324	27.77

Kluczowe odkrycie:
alpha=2.0 daje skokowa poprawe nad alpha=1.0: CE -1.6% (vocab=500), -1.9% (vocab=1000). Fertility spada (-2.5%) - tansze inference.

6. Skalowanie do rozmiarow produkcyjnych

Eksperymenty glowne uzywaly vocab=500 i 1000. Skalowalismy do vocab in {8000, 16000, 32000} przy alpha in {0.0, 1.0, 2.0}, na pelnym zbiorze treningowym (8000 tekstow, backend heurystyczny).

Vocab

8000	0.0	1.131	0.574 [0.569,0.578]	2.3h
8000	1.0	1.141	0.504 [0.499,0.509]	1.8h
8000	2.0	1.149	0.456 [0.451,0.460]	1.6h
16000	0.0	1.051	0.442 [0.438,0.446]	2.9h
16000	1.0	1.064	0.387 [0.384,0.391]	3.2h
16000	2.0	1.077	0.338 [0.335,0.342]	3.2h
32000	0.0	1.020	0.389 [0.385,0.393]	6.0h
32000	1.0	1.035	0.347 [0.343,0.351]	5.3h
32000	2.0	1.049	0.308 [0.304,0.311]	5.9h

Wyniki:

Przy wszystkich rozmiarach MorphBPE redukuje MorphED o 20,5%-23,4% (CI nie pokrywaja sie). Over-penalization daje dodatkowe 9,5%-12,6% redukcji. Najlepszy wynik: 32k alpha=2.0, MorphED=0.308.

Koszt fertility:

rosnie z vocab: +1.6% (8k), +2.5% (16k), +2.8% (32k). Nadal niewielki.

vs Bielik-11B (vocab=32k):

Bielik fertility=2.97. MorphBPE fertility=1.05 -

2.8x nizsza

przy tym samym rozmiarze slownika.

Wniosek:

Korzysc z MorphBPE nie tylko utrzymuje sie przy skalowaniu - jest 3-6x silniejsza niz przy vocab=500-1000.

7. Analiza bledow per-suffix

Transformer, vocab=1000, alpha=0.5. Delta < 0 = MorphBPE lepszy.

Sufiks

-ach	49	4.343	3.844	-11.5%
-ego	38	4.607	4.451	-3.4%
-osci	47	5.114	4.954	-3.1%
-enia	26	2.638	2.603	-1.3%
-ny	43	3.079	3.357	+9.0%
-ow	32	2.722	3.035	+11.5%
-ych	40	1.941	2.759	+42.1%
-owych	37	1.934	3.012	+55.8%
-c	49	3.579	5.577	+55.8%

Wzorzec:

MorphBPE zyskuje na sufiksach zlozonych (-ach, -ego, -osci), traci na krotkich (-c, -ych). Sugeruje adaptacyjna kare alfa wg dlugosci sufiksu.

8. Warunek obalenia

Teza upada, jesli: (1) fertility > +1% - aktualnie +0.04% (500), +2.8% (32k) - nie spelniony. (2) MorphED wzrasta - CI nie pokrywaja sie, MorphBPE < BPE - nie spelniony. (3) CE wzrasta - MorphBPE < BPE - nie spelniony.

Zaden z warunkow nie jest spelniony - synteza nie zostaje obalona.

9. Dyskusja

Glowny wynik:

MorphBPE suffix dominuje nad BPE na wszystkich metrykach przy obu rozmiarach slownika i obu architekturach. Korzysc rosnie z vocab: MorphED -3.6% -> -21.0%. Over-penalization (alpha=2.0) obniza

CE o kolejne 1.6%-3.1%.

Dlaczego dziala:

BPE optymalizuje tylko czestotliwosc par, co prowadzi do skalen przekraczajacych granice morfemow. MorphBPE kształtuje przestrzen skalen tak, aby granice sufiksow byly respektowane.

10. Ograniczenia i co dalej

Ograniczenia:

(1) male modele LM, (2) 500 tekstow treningowych LM, (3) wymaga Morfeusz2, (4) traci na sufiksach krotkich, (5) over-pen. testowane tylko na suffix.

Co dalej:

(1) ewaluacja extrinsic przy 32k (wymaga GPU), (2) adaptacyjna kara alfa, (3) test na czeskim/rosyjskim, (4) porownanie z SentencePiece, (5) over-pen. dla prefix i both.

Dokument autorstwa: Piotr Styla. Korpus: Polish Sejm Corpus (sejm.gov.pl).
Kod: morphbpe (pip-installable, CLI, 29 testow). Skrypty: paper_experiments.py, scale_vocab.py, benchmark_dawidek.py.
Data: 2026.