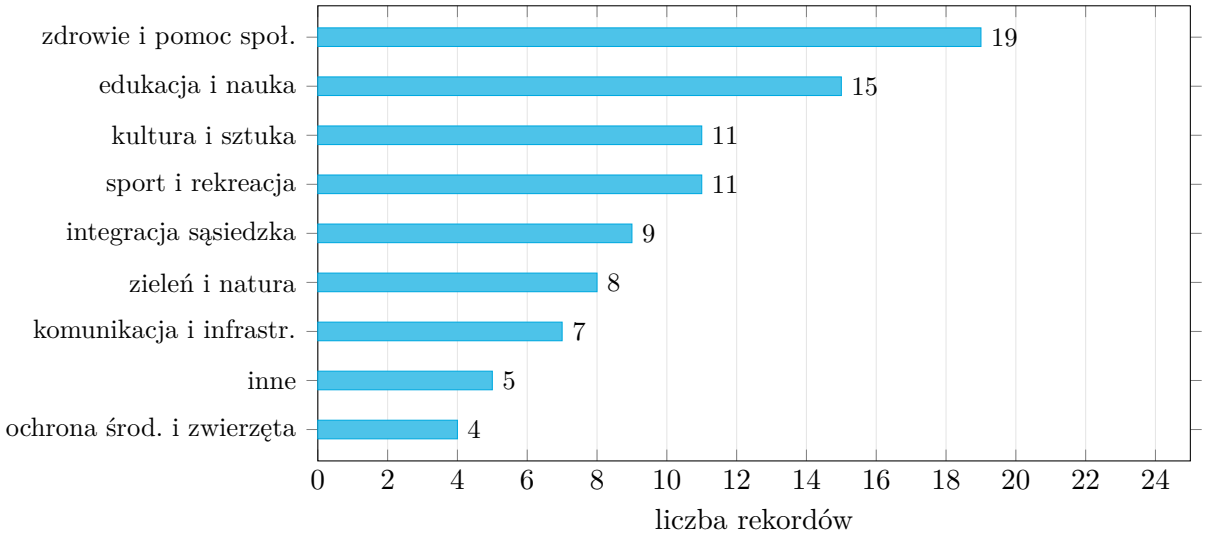
Warsaw Civic Budget 2027 — Seed datasetu języka współczesnej polszczyzny

PiotrStyla

26 czerwca 2026



Rysunek 1: Rozkład 89 rekordów według kategorii (152 526 znaków, 9 kategorii, 16 dzielnic). Źródło: Budżet Obywatelski Warszawy 2027, CC BY-SA 4.0. Dominuje zdrowie i pomoc społeczna (19 rek.), edukacja (15 rek.), kultura i sport (po 11 rek.). Zero duplikatów i danych kontaktowych.

Streszczenie

Budujemy seed datasetu języka współczesnej polszczyzny z opisów projektów Budżetu Obywatelskiego Warszawy 2027 (licencja CC BY-SA 4.0). Aktualny stan: 89 rekordów, 152 526 znaków, 9 kategorii, 16 dzielnic; 80 pełnych kart ze stabilnym `source_url` i kompletną atrybucją. Analiza redundancji wykazała medianę podobieństwa TF-IDF = 0,034 w rdzeniu pełnych kart — poziom niski, porównywalny z niezależnymi dokumentami. Seed spełnia kryteria recenzji v0.1, lecz nie jest jeszcze dojrzałym datassetem produkcyjnym.

1 Wprowadzenie

Pytanie: czy opisy projektów Budżetu Obywatelskiego Warszawy 2027 dostarczają reprezentatywny i nieredundantny zbiór języka codziennej polszczyzny, przydatny jako materiał treningowy dla Slayera?

Nitka dialektyczna:

Teza (T): Zbiór 80 pełnych kart (149 657 znaków tekstu z kart) o tematyce zdrowia, edukacji, sportu i transportu tworzy audytowalny, licencjonowany seed języka codziennej polszczyzny.

Antyteza (A): Dziewięć krótkich rekordów listowych (mediana TF-IDF = 0,452) i jedna para wysokiego ryzyka (studnie oligoceńskie, TF-IDF = 0,679) osłabiają jednorodność zbioru; seed NIE jest gotowy do treningu produkcyjnego.

Centralny wniosek

Synteza (S): Rdzeń 80 pełnych kart przechodzi wszystkie kontrole jakości (zero duplikatów, zero danych kontaktowych, atrybucja 80/80). Usunięcie 9 rekordów listowych i karty-duplikatu studni (≈ 2,55% znaków) eliminuje główne ryzyko redundancji i otwiera drogę do wydania gotowego do recenzji zespołu.

2 Metoda

Źródło i licencja

Dane pochodzą z platformy Budżetu Obywatelskiego Warszawy 2027. Strona platformy wskazuje licencję Creative Commons BY-SA 4.0[1]. Każdy rekord zachowuje konkretny `source_url`, `license_url` i datę pobrania; atrybucja twórców przechowywana jest oddzielnie od tekstu treningowego.

Ekstrakcja i czyszczenie

Rekordy pozyskiwano ręcznie lub półautomatycznie z kart szczegółowych projektów (`detail_seed`). Dziewięć wcześniejszych rekordów pochodzi z widoku listy (`list_seed`) i zawiera słabsze opisy. Czyszczenie: usunięcie tagów HTML, zastąpienie numerów telefonów i adresów e-mail znacznikiem `[usunięto dane kontaktowe]`, wykluczenie rekordów zbyt krótkich (< 50 znaków). Styl językowy wnioskodawców został zachowany bez wygładzania.

[1] https://creativecommons.org/licenses/by-sa/4.0/

Deduplikacja i analiza redundancji

Duplikaty identyfikowane kluczem tekstowym. Podobieństwo par rekordów mierzone dwiema metrykami:

$$\mathrm{sim}_{\cos}(d_i, d_j) = \frac{\mathbf{v}_i \cdot \mathbf{v}_j}{\|\mathbf{v}_i\| \cdot \|\mathbf{v}_j\|}$$

gdzie $\mathbf{v}_k$ to wektor TF-IDF dokumentu d_k na słowach treściowych, oraz podobieństwo Jaccarda na 5-gramach wyrazowych:

$$J_5(d_i, d_j) = \frac{|G_5(d_i) \cap G_5(d_j)|}{|G_5(d_i) \cup G_5(d_j)|}$$

3 Wyniki

Stan ogólny

Tabela 1: Podsumowanie zbioru Warsaw Civic Budget 2027.

Metryka	Wartość
Rekordy treningowe	89
Znaki tekstu treningowego	152 526
Pełne karty (`detail`)	80
z czego znaki	149 657
Rekordy listowe (`list`)	9
z czego znaki	2 869
Kategorie	9
Dzielnice / poziomy	16
Najkrótszy tekst [znaki]	235
Najdłuższy tekst [znaki]	2 981
Brakujące pola (detail)	0 / 8 pól
Dane kontaktowe w tekście	0
Duplikaty po deduplikacji	0
Atrybucja pełnych kart	80 / 80

Redundancja

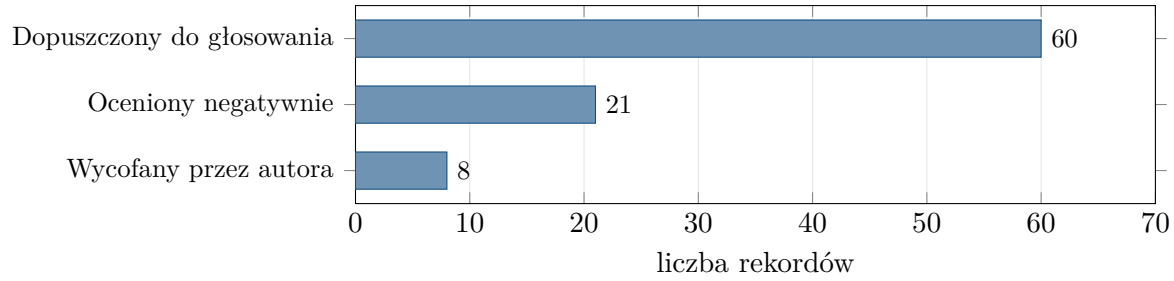
Tabela 2: Porównanie redundancji warstw danych (TF-IDF/kosinus, 5-gramy Jaccarda).

Warstwa	Rek.	Znaki	Med. sim.	Śr. sim.	Pary $\geq 0{,}50$
Pełne karty	80	149 657	0,034	0,036	0
Rek. listowe	9	2 869	0,452	0,511	12

Jedyna para wysokiego ryzyka w pełnych kartach to dwa projekty studni oligoceńskich: TF-IDF = 0,679, $\mathrm{Jaccard}_5$ = 0,269. Rekomendacja: usunąć krótszą kartę (ul. Kołacińska, ≈ 1 016 znaków).

Status projektów

Odwołania: rys. 1 (rozkład kategorii), rys. 2 (statusy), tab. 1, tab. 2.



Rysunek 2: Rozkład statusów 89 rekordów. 60 projektów dopuszczonych do głosowania (67,4%), 21 ocenionych negatywnie (23,6%), 8 wycofanych przez autora (9,0%). Uzasadnienia negatywnych ocen wzbogacają zbiór o rzadki rejestr urzędniczej polszczyzny.

4 Warunek obalenia

Teza o niskiej redundancji rdzenia pełnych kart upada, jeśli spełniony zostanie którykolwiek z poniższych warunków:

1. Liczba par pełnych kart z TF-IDF $\geq 0{,}50$ przekroczy 1% wszystkich par, czyli > 31 par spośród $\binom{80}{2} = 3\,160$. Aktualnie: **0 par**.
2. Odsetek rekordów z brakującym `license_url` wśród pełnych kart (detail) przekroczy 0%. Aktualnie: **0 brakujących / 80**.
3. Walidator wykryje dane kontaktowe w tekście treningowym. Aktualnie: **0 trafień**.

Żaden z warunków nie jest spełniony — synteza nie zostaje obalona.

5 Dyskusja

Ograniczenia. Seed pochodzi wyłącznie z jednego miasta (Warszawa) i jednej edycji (2027), co ogranicza geograficzną i czasową różnorodność. Kategorie są nierównomiernie reprezentowane: zdrowie dominuje (19 rek.), ochrona środowiska jest niedoreprezentowana (4 rek.). Dziewięć rekordów listowych wnosi metadane, lecz słabe opisy tekstowe — ich wartość treningowa jest istotnie niższa od pełnych kart (mediana TF-IDF = 0,452 vs 0,034).

Co dalej. Trzy priorytety kolejnego etapu: (1) usunąć lub zastąpić 9 rekordów listowych pełnymi kartami, (2) usunąć kartę studni przy ul. Kołacińskiej (TF-IDF = 0,679), (3) wyrównać kategorie przez dobór kart z ochrony środowiska, komunikacji i kultury. Po korekcie szacowana strata to $\approx 3\,885$ znaków (2,55% zbioru), a zysk to wyraźnie czystszy i jednorodniejszy rdzeń treningowy.

Podpis

Dokument autorstwa: *PiotrStyla*. Dane: CC BY-SA 4.0, Budżet Obywatelski Warszawy 2027. Skompilowany w CI (`.tex` → PDF, artefakt `raport-pdf`). Data: 26 czerwca 2026.